

PROYECTO FINAL

Walter Quispe Vargas
Docente

Curso:
Introducción a Ciencia de Datos e Inteligencia Artificial

20 de Agosto del 2026

**CIENCIA DE DATOS E
INTELIGENCIA ARTIFICIAL**

☎ (+51) 900 000 007
✉ wquispev@utec.edu.pe

Tabla de contenidos

1. INTRODUCCIÓN	3
2. ESTRUCTURA GENERAL DEL PROYECTO	3
3. CRITERIOS DE EVALUACIÓN Y USO DE INTELIGENCIA ARTIFICIAL	3
4. LISTA DE DATASETS DISPONIBLES	4
4.1. Tareas de Clasificación	4
5. ENTREGA P1 – EXPLORACIÓN Y PREPROCESAMIENTO	4
5.1. Objetivo	5
5.2. Estructura Esperada (Referencial)	5
5.3. Entregables de P1	6
6. ENTREGA P2 – MODELAMIENTO, EVALUACIÓN Y AUDITORÍA	7
6.1. Objetivo	7
6.2. Estructura Esperada (Referencial)	7
6.3. Entregables de P2	9
7. OBSERVACIONES FINALES	9

1. INTRODUCCIÓN

El presente proyecto busca aplicar de forma práctica los conocimientos fundamentales de Ciencia de Datos e Inteligencia Artificial adquiridos a lo largo del curso. Está dividido en dos fases (entregas) que abarcan de forma progresiva el ciclo completo de un proyecto real de análisis de datos: desde la identificación del problema, adquisición y preparación de un conjunto de datos, pasando por su exploración estadística, hasta la construcción, evaluación y auditoría de un modelo predictivo usando algoritmos de Machine Learning.

El objetivo principal es que cada estudiante sea capaz de estructurar un proyecto ordenado, justificado y reproducible, tal como se espera en entornos profesionales. Se espera rigurosidad en la limpieza de datos, claridad en los gráficos y análisis, una explicación detallada de cada decisión tomada y un nivel de pensamiento crítico profundo al momento de evaluar los fallos del modelo implementado.

2. ESTRUCTURA GENERAL DEL PROYECTO

Cada entrega debe incluir dos productos clave:

1. Un archivo comprimido con todos los documentos necesarios para ejecutar el template compartido en clases (*UTEC-Report.zip*) con códigos de python, R, Latex y markdown ordenado y comentado.
2. Una presentación visual (En formato .html, compartido en clases) que resuma y explique el proceso de análisis, resultados obtenidos y conclusiones.

Importante: Todas las decisiones deben estar justificadas técnica o estadísticamente. Cada gráfico debe ir acompañado de su interpretación y el porqué de su uso.

3. CRITERIOS DE EVALUACIÓN Y USO DE INTELIGENCIA ARTIFICIAL

En este curso fomentamos la adopción de herramientas tecnológicas modernas. Por lo tanto, el uso de agentes inteligentes (tales como *ChatGPT*, *Gemini*, *Claude*, *GitHub Copilot*, entre otros) está permitido y fomentado para propósitos de corrección de errores (*debugging*), consulta de sintaxis de librerías o apoyo en la estructuración del código.

Sin embargo, el objetivo principal del curso es desarrollar el razonamiento analítico. Por ello, la evaluación del proyecto no se basará únicamente en entregar un código funcional, sino en la profundidad del proceso de toma de decisiones. Durante la evaluación y exposición se aplicarán los siguientes criterios:

- **Justificación de Decisiones Técnicas:** Se exigirá explicar el porqué detrás de cada bloque de código. Por ejemplo: por qué se decidió imputar un valor faltante con la mediana en lugar de eliminar la fila, por qué se aplicó una transformación logarítmica a una variable, o por qué se seleccionó un tipo de gráfico específico.
- **Interpretación sobre Ejecución:** Un código que compila y se ejecuta perfectamente, pero que carece de interpretación estadística o conclusiones de negocio en los espacios de texto (*Markdown*), obtendrá una calificación deficiente. El estudiante debe demostrar que comprende e interpreta las salidas de sus propios algoritmos.
- **Dominio del Proyecto (Defensa Oral):** Los estudiantes deberán ser capaces de explicar la lógica de cualquier sección de su *notebook*. Si el estudiante no puede explicar cómo funciona un bloque de código que fue generado por una IA, se considerará una falta al rigor académico.
- **Valoración del Pensamiento Crítico (“Autopsia”):** Desde la perspectiva de evaluación, un proyecto con un modelo de precisión moderada (ej. 70 %) pero acompañado de un análisis de fallos (Autopsia) profundo, honesto e investigativo, será calificado con una nota muy superior a un proyecto con un modelo de precisión irreal (ej. 99 %) tratado como una “caja negra” y sin justificación.

4. LISTA DE DATASETS DISPONIBLES

Cada grupo de 5 integrantes deberá elegir uno de los siguientes conjuntos de datos para desarrollar su proyecto. Un máximo de 2 grupos podrán usar el mismo dataset, para ello deberán llenar el siguiente excel, colocando los integrantes de cada grupo y un representante del grupo. [Link de Excel para los grupos](#)

4.1. Tareas de Clasificación

1. Rendimiento de Estudiantes: [Student Performance](#)
2. Fuga de Clientes Telco: [Telco Customer Churn](#)
3. Detección de Fraudes de Seguros: [Vehicle Insurance Claim Fraud Detection](#)
4. Satisfacción de Pasajeros: [Airline Passenger Satisfaction](#)
5. Predicción del uso y adicción de celulares: [Smartphone Usage & Addiction Prediction](#)
6. Marketing en los Bancos: [Bank Marketing](#)

5. ENTREGA P1 – EXPLORACIÓN Y PREPROCESAMIENTO

5.1. Objetivo

Aplicar las etapas iniciales de un proyecto de Ciencia de Datos:

- Comprensión y contextualización del dataset
- Limpieza de datos
- Análisis exploratorio con visualizaciones

5.2. Estructura Esperada (Referencial)

1. Contexto del Dataset

- Descripción del problema.
- Fuente del dataset.
- Objetivo del análisis (¿qué se desea predecir o entender?).

2. Carga y Exploración Inicial

- Dimensiones y estructura del dataset.
- Tipos de variables y primeras estadísticas.
- Visualización de la distribución de valores nulos, etc.

3. Preprocesamiento de los datos (Data Wrangling)

- Identificación y tratamiento de valores nulos y duplicados.
- Transformación de tipo de datos.
- Cambio de nombre de columnas.
- Justificación de métodos de imputación: media, eliminación, etc.
- Enriquecimiento de los datos - Creación de nuevas variables. (Ejemplo: Cálculo de la edad a partir de la fecha de nacimiento, etc.)

4. Análisis Exploratorio de Datos (EDA)

a. Análisis Univariado

- Boxplots: Para cada variable numérica, se grafican boxplots que permiten visualizar la dispersión, posibles outliers y simetría. Se deben comentar los hallazgos relevantes por variable.
- Histogramas: Se genera un histograma por cada variable numérica para analizar la distribución de frecuencias. Se debe interpretar la forma de la distribución y su implicancia.

- Gráficos de barras: Aplicables a variables categóricas, muestran la frecuencia de cada categoría. Se debe explicar qué representa cada gráfico y resaltar categorías dominantes o atípicas.
- Medidas de tendencia central: Media, mediana y moda por variable.
- Medidas de dispersión: Desviación estándar, varianza, rangos, cuartiles.
- Se debe interpretar cada estadístico en el contexto de los datos, destacando casos de alta dispersión o valores extremos.

b. Análisis Multivariado

- Mapa de calor de correlaciones: Aplica a variables numéricas. Permite identificar relaciones lineales fuertes y posibles problemas de colinealidad.
- Boxplots comparativos: Comparación de una variable numérica entre grupos definidos por una variable categórica.
- Histogramas y gráficos de barras agrupadas: Comparaciones de distribuciones y frecuencias entre subgrupos.
- Diagramas de dispersión (scatterplots): Se deben incluir al menos 5 combinaciones de pares de variables numéricas. Permiten observar tendencias, patrones lineales/no lineales y agrupamientos.
- Se debe incluir la interpretación de cada uno de los gráficos.
- Covarianza: Medida de relación lineal entre pares de variables numéricas. Se interpreta su signo e intensidad.
- Correlación: Se analiza el coeficiente (Pearson, Spearman, etc.), destacando relaciones fuertes o débiles, positivas o negativas.

c. Conclusiones Generales del EDA

- Resumen de hallazgos relevantes a nivel univariado y multivariado.
- Discusión sobre la presencia de colinealidad y posibles relaciones lineales.
- Identificación de variables clave que aportan valor al análisis.

5.3. Entregables de P1

- UTEC-Report1.zip
- UTEC-Presentation
 - Introducción del dataset.
 - Proceso de limpieza y decisiones.
 - Principales insights obtenidos del análisis.

6. ENTREGA P2 – MODELAMIENTO, EVALUACIÓN Y AUDITORÍA

6.1. Objetivo

Construir un modelo de aprendizaje supervisado para clasificar datos según el dataset elegido, explicando su lógica algorítmica y evaluando críticamente sus fallos.

6.2. Estructura Esperada (Referencial)

1. Preparación Final del Dataset

- Selección de features relevantes - Eliminación de variables irrelevantes.
- Medición de la fuerza predictora de las variables.
- Codificación de variables categóricas.
- Normalización o estandarización si es necesario.

2. División en Conjuntos de Entrenamiento y Prueba

- Uso de `train_test_split`.
- Justificación del porcentaje elegido (ej. 80/20 o 70/30).

3. Entrenamiento de Modelos de *Machine Learning*

a. Selección de Modelos

- Selección de al menos dos modelos adecuados para tareas de clasificación. En caso escoja un modelo fuera de la lista proporcionada, justifique su elección.
- Modelos para problemas de clasificación:
 - Regresión Logística
 - Árboles de Decisión (con límite de profundidad para visualización)
 - Support Vector Machines (SVM)
 - K-Nearest Neighbors (KNN) para clasificación
 - XGboost
- Justificación técnica y conceptual para cada modelo seleccionado en función de los datos y del objetivo del análisis.

b. Entrenamiento y Ajuste de Modelos

- Entrenamiento de los modelos seleccionados.
- Ajuste de hiperparámetros utilizando técnicas como grid search o random search.

c. Evaluación de Modelos

- *Accuracy*
- *F1-Score (Precision y Recall)*
- Matriz de Confusión

4. Explicabilidad del Modelo

- Extracción de Casos: El estudiante deberá aislar del conjunto de prueba (X_{test}) tres (3) registros reales que hayan sido clasificados correctamente por su mejor modelo, imprimiendo en pantalla los valores exactos de sus variables.
- Análisis de Probabilidades: Utilizar la función de probabilidad del modelo (ej. *predict_proba()*) para mostrar la confianza matemática con la que la IA clasificó dichos registros.
- Justificación Algorítmica Paso a Paso: En una celda de Markdown, explicar exactamente cómo el modelo llegó a esa conclusión basándose en su algoritmo.
 - Si se usó un Árbol de Decisión, se debe adjuntar el gráfico del árbol y describir textualmente el camino (condición por condición) que siguió el dato hasta la hoja final.
 - Si se usó Regresión Logística / SVM, se debe mencionar cuáles son los coeficientes de las variables más fuertes que empujaron el dato hacia esa clase.
 - Si se usó KNN, se debe justificar en base a las características de los “K” vecinos más cercanos a ese registro.
 - Si se usó XGBoost, debe justificar la elección de los hyperparametros como (*learning_rate*, *num_trees*, etc)

5. Autopsia del Modelo (Análisis de Fallos)

- Construcción del DataFrame de Errores: Se debe escribir código en Pandas para crear un DataFrame que contenga exclusivamente las filas donde la predicción del modelo (y_{pred}) es distinta al valor real (y_{test}).
- Clasificación del Error: Para cada registro filtrado, identificar claramente si el modelo cometió un Falso Positivo (Error Tipo I) o un Falso Negativo (Error Tipo II), y explicar en texto qué significa este error en el contexto de su problema de negocio.
- Análisis Manual a Nivel de Registro (*Deep-Dive*): Seleccionar manualmente cinco (5) filas específicas de este nuevo DataFrame de errores. Para cada una, listar sus valores e intentar razonar por qué el modelo se confundió.

- Hipótesis y Solución Propuesta: Para los 5 casos analizados, formular una hipótesis técnica en Markdown. (Ejemplo: “Creemos que el modelo falló porque este cliente tiene un plan premium pero ingresos bajos, lo cual es inusual y lo acercó a la frontera de decisión”). Seguidamente, proponer una solución futura, como recolectar una nueva variable o agrupar sub-categorías.

6. Comparación de Modelos y Conclusiones

- a. Comparación del rendimiento de los modelos según las métricas aplicadas.
- b. Discusión de ventajas, limitaciones y comportamiento de cada modelo.
- c. Conclusiones generales:
 - Evaluación del impacto de los datos en el rendimiento (balanceo, calidad, outliers).
 - Recomendaciones sobre mejoras de datos evidenciadas durante la autopsia del modelo (nuevas variables necesarias, transformación, ingeniería de *features*).
 - Consideraciones éticas o de impacto real en caso de implementarse la solución actual.

6.3. Entregables de P2

- UTEC-Report-final.zip: Con código comentado, estructura clara y justificaciones analíticas profundas en las celdas de *Markdown*.
- UTEC-Presentation-final (html) que incluya:
 - Elección del modelo y razonamiento.
 - Resultados y métricas principales.
 - Defensa de la explicabilidad (ejemplo visual y paso a paso de cómo decide el modelo).
 - Resumen de la “Autopsia” (presentando al menos 2 casos fallidos) y principales conclusiones técnicas y éticas.

7. OBSERVACIONES FINALES

- Toda visualización debe incluir su razón de ser y una interpretación clara.
- Toda transformación debe estar respaldada por una justificación técnica.
- La organización del reporte, calidad del código y la profundidad de la claridad explicativa y crítica son claves para una buena evaluación.
- Puedes usar librerías en **Python** como *pandas*, *numpy*, *matplotlib*, *seaborn*, *scikit-learn*, etc.
- Puedes usar librerías en **R** como *tidiverse*, *tidimodels*, *ggplot2*, etc.