

Explicación profunda de la presentación

Proyecto: Aceptación de depósitos a plazo en campañas de telemarketing bancario

Documento de defensa técnica: datos, gráficos, resultados, interpretación y cautelas metodológicas

Cómo usar este documento

Cada apartado corresponde a una página de la presentación. La idea no es leerlo completo durante la exposición, sino estudiar el fundamento detrás de cada diapositiva para responder preguntas con profundidad.

Conceptos clave antes de empezar

- Tasa de aceptación = número de clientes que suscriben dividido entre número total de clientes del grupo. Se usa para comparar categorías con tamaños distintos.
- Desbalance de clases = la mayoría de registros pertenece a la clase No. Por eso los conteos absolutos pueden ocultar patrones en grupos pequeños.
- Asociación descriptiva no es causalidad. El EDA muestra patrones observados, pero no prueba que una variable cause la aceptación.
- Fuga de información = usar una variable que no estaría disponible al momento de tomar la decisión. En este proyecto, duración es el ejemplo principal.
- Colinealidad = variables que contienen información muy parecida. En este proyecto ocurre entre indicadores macroeconómicos.

Página 1: Portada

Tipo de página
Apertura de la exposición

Tipo de datos usados

No presenta datos todavía; ubica el tema, integrantes, curso y periodo académico.

Explicación detallada

La portada cumple una función de encuadre. El título anuncia que el producto analizado es un depósito a plazo y que el canal comercial es telemarketing bancario. Eso ya sugiere que el problema combina tres dimensiones: perfil financiero del cliente, comportamiento de contacto y contexto económico.

Aunque dice proyecto final, esta presentación corresponde a la Entrega 1: exploración y preprocesamiento. En defensa conviene aclarar que todavía no se entrena un modelo; se construye la base analítica para una etapa posterior de modelamiento.

Resultado o lectura principal

El mensaje inicial debe dejar claro que no se busca vender una solución automática todavía, sino entender qué variables parecen explicar diferencias de aceptación.

Qué decir si preguntan

Si preguntan por qué se eligió este dataset, responder que es una tarea de clasificación binaria clara, con variable objetivo y variables mixtas: categóricas, numéricas, operativas y macroeconómicas.

Página 2: Introducción del dataset

Tipo de página
Diapositiva de sección

Tipo de datos usados

Presenta el inicio del bloque de contexto. No contiene gráfico, pero organiza la narrativa.

Explicación detallada

La sección introduce la fuente y el problema de negocio antes de mostrar números. Esto es importante porque los resultados estadísticos no se interpretan en vacío: se interpretan según el proceso comercial de llamadas y aceptación de depósitos.

En esta presentación, las secciones funcionan como separadores: primero contexto, luego limpieza y finalmente hallazgos. Eso ayuda a que el profesor vea el flujo completo del ciclo de datos: entender, preparar, explorar e interpretar.

Resultado o lectura principal

La función de esta página es preparar al público para entender de dónde vienen los datos y qué significa aceptar un depósito.

Qué decir si preguntan

Puedes decir que antes de calcular métricas era necesario definir el contexto, la unidad de análisis y la variable objetivo.

Página 3: Contexto y objetivo

Tipo de datos usados

Datos mixtos. Cada fila representa un contacto de campaña. Hay 41,188 registros, 20 variables predictoras y una variable objetivo binaria: y, recodificada como suscribió Sí/No.

Explicación detallada

La parte izquierda resume el problema. El banco contacta masivamente a clientes para vender depósitos a plazo. Este producto es de ahorro: el cliente entrega dinero al banco por un tiempo acordado. El problema es que la estrategia masiva genera costo operativo alto y baja eficiencia si la mayoría rechaza.

La tabla derecha es una ficha técnica. La fuente es UCI Bank Marketing, basada en Moro et al. (2014). El periodo va de mayo de 2008 a noviembre de 2010, lo cual es clave porque coincide con un contexto posterior a la crisis financiera. Las variables se agrupan en perfil del cliente, campaña/contacto e indicadores económicos.

El objetivo está formulado de forma exploratoria: identificar características asociadas con mayor aceptación. La palabra asociadas es importante porque el EDA no prueba causalidad; solo detecta patrones y diferencias entre grupos.

Resultado o lectura principal

La diapositiva define el problema: mejorar la eficiencia de campañas identificando qué perfiles, contactos y contextos se relacionan con una mayor probabilidad de aceptación.

Qué decir si preguntan

Si preguntan por la unidad de análisis, responder: una fila es un contacto de campaña, no necesariamente un cliente único identificado, porque el dataset no incluye ID de cliente.

Página 4: El problema en una cifra

Tipo de datos usados

Variable categórica binaria y/no, recodificada como No/Sí. Se grafican frecuencias absolutas y porcentajes: 36,548 rechazos y 4,640 aceptaciones.

Explicación detallada

El gráfico de barras compara cuántos contactos terminaron en suscripción frente a cuántos no. Es el primer gráfico porque cuantifica el problema de negocio: la campaña tiene una tasa de éxito baja.

El 11.27% de aceptación se calcula como 4,640 aceptaciones dividido entre 41,188 contactos. El 88.73% restante corresponde a rechazos. El ratio 1:7.88 significa que por cada cliente que acepta hay casi ocho que no aceptan.

Esta distribución revela desbalance de clases. En EDA eso implica que los conteos pueden engañar: una categoría puede tener muchos rechazos simplemente porque el grupo No domina todo el dataset. Por eso, en los siguientes gráficos se usa tasa de aceptación por categoría, no solo volumen.

Resultado o lectura principal

El problema no es menor: la campaña invierte la mayor parte de sus llamadas en contactos que no convierten.

Qué decir si preguntan

Si preguntan por qué no usar accuracy en esta etapa, responder que todavía no hay modelo y además el desbalance haría que métricas simples sean poco informativas.

Página 5: Limpieza y decisiones

Tipo de página

Tabla de problemas de calidad y decisiones de preprocesamiento

Tipo de datos usados

Se trabaja con datos crudos y se documentan decisiones: duplicados, valores unknown, valor especial 999, renombrado de columnas, conversión a category y tratamiento de atípicos.

Explicación detallada

Esta tabla es una auditoría resumida del preprocesamiento. No se limita a decir que se limpió el dataset; indica qué problema se encontró y por qué se tomó una decisión específica.

Las 12 filas duplicadas representan 0.029% del total. Se eliminan porque coinciden en todas las variables, incluida la duración de llamada y variables de campaña. Aunque no hay ID de cliente, la coincidencia total sugiere duplicación de registro y su eliminación no altera las distribuciones.

Los unknown aparecen en seis variables categóricas. No se eliminan automáticamente porque en datos bancarios la ausencia de información puede tener significado: por ejemplo, clientes sin historial crediticio.

El valor pdays=999 no es un número real de días. Es un código semántico: nunca contactado. Tratarlo como número distorsionaría medias y correlaciones.

Los atípicos se conservan porque son plausibles: llamadas muy largas, clientes mayores o muchos contactos no son necesariamente errores; pueden revelar patrones de negocio.

Resultado o lectura principal

Después de limpiar, el dataset queda en 41,176 filas y 26 columnas. Las columnas adicionales provienen de nuevas variables derivadas.

Qué decir si preguntan

Una respuesta fuerte es: no aplicamos limpieza mecánica; cada decisión se justificó con significado de negocio, proporción afectada y efecto estadístico.

Página 6: ¿Qué hacer con los valores desconocidos?

Tipo de página

Gráfico de barras de porcentajes unknown y regla de imputación

Tipo de datos usados

Variables categóricas con etiqueta unknown: default/mora, education/educación, housing/vivienda, loan/préstamo, job/empleo y marital/estado civil. El gráfico muestra porcentaje de unknown por variable.

Explicación detallada

El gráfico de barras permite comparar qué variables tienen más datos desconocidos. La más crítica es mora, con 20.87% de unknown. Educación tiene 4.20%, vivienda y préstamo 2.40%, empleo 0.80% y estado civil 0.19%.

La regla de decisión fue estadística y de negocio: comparar la tasa de aceptación del grupo unknown con la tasa general y con las categorías conocidas. Si unknown se comporta diferente, se conserva como categoría; si se parece al resto, se imputa con la moda.

En mora, los unknown aceptan 5.15%, frente a 12.88% cuando se conoce que no hay mora. Esto sugiere que el unknown no es ruido aleatorio: identifica un segmento con menor propensión, quizá clientes sin historial crediticio claro. Por eso se conserva como desconocido.

En educación, unknown tiene 14.51%, mayor que categorías con volumen relevante. Por tanto, también se conserva como segmento. En vivienda, préstamo, empleo y estado civil las diferencias no justifican una categoría especial, o

el grupo es demasiado pequeño; por eso se usa moda.

Resultado o lectura principal

La decisión evita dos errores: eliminar muchas filas útiles o imputar de forma ciega grupos que sí tienen comportamiento propio.

Qué decir si preguntan

Si preguntan por qué usar moda, explicar que se usó solo cuando el grupo unknown no mostraba una tasa de aceptación suficientemente distinta o tenía pocos casos.

Página 7: El valor 999 y las nuevas variables

Tipo de página
Explicación de variable especial y feature engineering interpretable

Tipo de datos usados

pdays/dias_previos es cuantitativa discreta en apariencia, pero contiene un código especial: 999. Se crean dias_desde_contacto, contacto_previo, duracion_min, tramo_duracion y grupo_etario.

Explicación detallada

Esta diapositiva separa un punto metodológico clave: no todo número debe tratarse como magnitud. En pdays, 999 significa nunca contactado. Si se deja en la media, el promedio es 962.46 días, lo cual no describe tiempo real sino mezcla de clientes sin historial con clientes contactados.

Al excluir el 999, la media real para clientes con contacto previo es 6.01 días. Esa diferencia muestra cómo un código especial puede destruir la interpretación estadística si no se entiende el diccionario de datos.

dias_desde_contacto conserva solo días reales y deja nulo cuando no aplica. Esos nulos no se imputan porque no son datos faltantes: conceptualmente no existe un último contacto. contacto_previo conserva la información binaria de si el cliente tenía historial.

Las nuevas variables mejoran legibilidad: duracion_min convierte segundos a minutos; tramo_duracion agrupa llamadas; grupo_etario permite comparar etapas de vida; contacto_previo resume historial. Todas son transformaciones simples, defendibles y fáciles de interpretar.

Resultado o lectura principal

La limpieza no solo corrige datos; también construye variables que hacen posible interpretar patrones de negocio.

Qué decir si preguntan

Puedes decir que se evitó inventar valores para dias_desde_contacto porque imputar un promedio a clientes nunca contactados habría creado información falsa.

Página 8: Principales hallazgos

Tipo de página
Diapositiva de sección

Tipo de datos usados

No muestra datos nuevos; abre el bloque de resultados del EDA multivariado.

Explicación detallada

Esta página marca la transición desde preprocesamiento hacia interpretación. El análisis ya no se centra en calidad de datos, sino en patrones que ayudan a entender la aceptación.

Los hallazgos se ordenan desde señales más fuertes y accionables hacia advertencias metodológicas. Primero historial del cliente, luego contexto económico, perfil, insistencia, estacionalidad, duración y colinealidad.

Resultado o lectura principal

La estructura permite construir una historia: quién acepta más, bajo qué contexto, cómo influye la campaña y qué variables deben tratarse con cuidado.

Qué decir si preguntan

Si quieren sonar sólidos, indiquen que no se eligieron hallazgos por intuición sino por diferencias de tasa de aceptación y relaciones estadísticas observadas.

Página 9: 1. El historial del cliente es la mejor señal

Tipo de página
Dos gráficos de barras de tasa de aceptación

Tipo de datos usados

Variables categóricas: resultado_previo y contacto_previo. La métrica graficada es tasa de aceptación por categoría. Se incluye una línea de referencia de tasa general: 11.27%.

Explicación detallada

El primer gráfico compara categorías del resultado de la campaña anterior: nonexistent, failure y success. El hallazgo central es que success tiene 65.11% de aceptación. Incluso failure tiene 14.23%, por encima de clientes sin historial, que aceptan 8.83%. Esto indica que haber interactuado antes con el banco deja una señal importante.

El segundo gráfico compara contacto_previo Sí/No. Los clientes con contacto previo aceptan 63.83%, frente a 9.26% sin contacto previo. Es una diferencia enorme, pero hay que recordar que solo 1,515 clientes, es decir 3.68%, tienen contacto previo.

El gráfico usa tasas y no conteos porque el grupo sin historial es mucho más grande. Si miráramos solo volumen, parecería que el grupo sin historial domina todo; pero la eficiencia está en la tasa.

Resultado o lectura principal

El historial previo es el segmento más eficiente. Una campaña futura podría priorizar clientes con interacción anterior, aunque el volumen sea pequeño.

Qué decir si preguntan

Cuidado: no decir que el historial causa aceptación. Puede ser que esos clientes ya fueran mejores prospectos. Lo correcto es decir que está fuertemente asociado.

Página 10: 2. El contexto económico también importa

Tipo de página
Histograma/densidad por grupo de suscripción para euribor3m

Tipo de datos usados

Variable numérica continua: euribor3m. Se compara su distribución entre suscribió Sí y No usando densidad para que el desbalance no oculte la forma de cada grupo.

Explicación detallada

Este gráfico no compara conteos absolutos sino formas de distribución. Se usa stat=density y common_norm=False para que cada grupo, Sí y No, se normalice por separado. Esto es correcto porque hay muchos más No que Sí.

La masa de los clientes que no aceptan está más concentrada en valores altos de Euribor, alrededor de 4% a 5%. En cambio, quienes aceptan aparecen con mayor peso en valores bajos, alrededor de 1% a 2%.

La tabla-resumen detrás de la diapositiva divide Euribor en menor a 3% y mayor o igual a 3%. Con Euribor menor a 3%, la aceptación es 24.46%; con Euribor de 3% o más, cae a 4.84%. La diferencia es de aproximadamente cinco veces.

La interpretación económica es que durante periodos de tasas bajas y de incertidumbre posterior a la crisis, los depósitos a plazo pudieron verse como alternativa segura de ahorro. Pero esto debe leerse como asociación temporal, no causalidad individual.

Resultado o lectura principal

El contexto macroeconómico es tan importante como el perfil del cliente: el momento de la campaña influye en la propensión observada.

Qué decir si preguntan

Si preguntan por qué usar Euribor, responder que además de ser interpretable, resume bien el ciclo económico y se relaciona fuertemente con otras variables macro.

Página 11: 3. Los extremos de edad aceptan más

Tipo de página
Dos gráficos de barras de tasa: grupo etario y empleo

Tipo de datos usados

Variables categóricas derivadas y originales: grupo_etario y empleo. La métrica es tasa de aceptación por categoría, con referencia a tasa general.

Explicación detallada

El gráfico de edad muestra una relación no lineal: no aumenta o disminuye de forma simple con la edad. Los extremos aceptan más. Clientes de 65 o más llegan a 47.28% y los de 17 a 24 a 23.99%. En cambio, los grupos intermedios, especialmente 35 a 54, rondan 8.6%.

El gráfico de empleo complementa esa lectura. Estudiantes aceptan 31.43% y jubilados 25.26%, lo que coincide con los extremos de edad. Obreros, servicios y algunos grupos laborales tradicionales aceptan menos.

Este hallazgo revela una posible ineficiencia de segmentación: los grupos centrales de edad fueron muy contactados, pero no necesariamente son los más propensos. La campaña parece concentrarse en adultos en edad laboral, aunque los extremos convierten mejor.

También hay que tener cuidado con el tamaño de los grupos. Un grupo con pocos registros puede tener tasas altas más inestables. Por eso se debe mencionar como segmento a investigar, no como regla absoluta.

Resultado o lectura principal

Los perfiles jóvenes y mayores merecen atención porque, aunque tienen menos volumen, muestran mayor aceptación relativa.

Qué decir si preguntan

Si preguntan por el uso de grupos etarios, decir que convertir edad continua en rangos facilita interpretación comercial, aunque se pierde algo de detalle numérico.

Página 12: 4. Insistir no funciona

Tipo de página
Gráfico de barras por número de contactos en campaña

Tipo de datos usados

Variable numérica campaign transformada a tramos: 1, 2, 3, 4-5, 6-10, más de 10. Métrica: tasa de aceptación por tramo. También se menciona canal de contacto.

Explicación detallada

El gráfico muestra cómo cambia la aceptación según cuántas veces se contactó al mismo cliente durante la campaña actual. Con un solo contacto, la tasa es 13.04%, ligeramente superior a la tasa general. Con más de 10 contactos, baja a 3.11%.

Desde el tercer contacto, la tasa queda por debajo del promedio general. Esto sugiere rendimientos decrecientes: insistir más no necesariamente aumenta la venta; puede estar asociado a clientes menos interesados o conversaciones más cortas.

La diapositiva también menciona el canal: celular convierte 14.74%, teléfono fijo 5.23%. Esto indica que el medio de contacto importa. El celular probablemente facilita disponibilidad, respuesta o calidad del contacto.

Metodológicamente, no se debe concluir que llamar muchas veces causa rechazo. Puede haber sesgo de selección: se insiste más en clientes difíciles. Aun así, como decisión operativa, sirve para cuestionar el costo de insistir.

Resultado o lectura principal

La recomendación natural es limitar contactos repetidos y priorizar canales más eficientes, especialmente celular.

Qué decir si preguntan

Si preguntan por causalidad, responder: no demostramos causalidad, pero sí una asociación operacional útil para revisar reglas de campaña.

Página 13: 5. Mayo: mucho volumen, poca conversión

Tipo de página

Dos gráficos: volumen de contactos por mes y tasa de aceptación por mes

Tipo de datos usados

Variable categórica ordinal mes. Gráfico izquierdo: porcentaje de contactos. Gráfico derecho: tasa de aceptación. Permite comparar volumen versus eficiencia.

Explicación detallada

Esta diapositiva es potente porque pone lado a lado cantidad y eficiencia. El gráfico izquierdo muestra que mayo concentra 33.43% de las llamadas. Eso indica una fuerte concentración operativa en un mes.

El gráfico derecho muestra que mayo tiene la tasa más baja: 6.44%. Por contraste, marzo, septiembre, octubre y diciembre superan el 43%, pero con menos del 2% de llamadas cada uno. Esto revela una relación inversa entre volumen y conversión mensual.

La interpretación más prudente es que mayo pudo haber sido un mes de campaña masiva y poco segmentada, mientras que los meses de baja actividad quizá tuvieron clientes más seleccionados. El dataset no incluye la estrategia exacta de selección, así que esto queda como hipótesis.

Este análisis ilustra por qué mirar solo volumen puede ser engañoso. Un mes con muchas llamadas no necesariamente es un mes eficiente. Para gestión comercial, importa el costo por depósito captado y no solo cuántos clientes se contactan.

Resultado o lectura principal

La planificación temporal de campañas parece relevante. Conviene revisar por qué meses con poco volumen convierten tanto mejor.

Qué decir si preguntan

Si preguntan por estacionalidad, decir que hay patrón por mes, pero está mezclado con selección de clientes y contexto económico.

Página 14: 6. La duración: muy asociada, pero solo se conoce después

Tipo de página
Gráfico de barras por tramos de duración de llamada

Tipo de datos usados

Variable duration transformada a duracion_min y luego a tramos: 0-1, 1-2, 2-3, 3-5, 5-10, más de 10 minutos.
Métrica: tasa de aceptación.

Explicación detallada

El gráfico muestra una relación monotónica fuerte: a mayor duración, mayor tasa de aceptación. Hasta 1 minuto, la aceptación es 0.02%, prácticamente cero. Entre 5 y 10 minutos sube a 18.58%, y más de 10 minutos llega a 48.61%.

La interpretación comercial es clara: las llamadas exitosas suelen durar más porque hay conversación, interés, explicación del producto y cierre. Las llamadas muy cortas probablemente representan rechazo temprano o cliente no disponible.

Pero esta es la diapositiva con la advertencia metodológica más importante. La duración se conoce al terminar la llamada. Si el objetivo futuro fuera predecir antes de llamar a quién contactar, usar duration sería fuga de información. El modelo estaría usando una variable que no existe en el momento de decisión.

Por eso la variable es útil para gestión en tiempo real o capacitación de agentes, pero no para selección previa de clientes. En una etapa de modelamiento realista, debe excluirse si se predice propensión antes del contacto.

Resultado o lectura principal

Duración es una señal fuerte de resultado, pero no una variable válida para priorizar clientes antes de la llamada.

Qué decir si preguntan

Esta explicación demuestra pensamiento crítico: no todas las variables predictivas estadísticamente fuertes son válidas para el caso de uso.

Página 15: 7. Indicadores económicos que se mueven juntos

Tipo de página
Mapa de calor de correlación de Pearson

Tipo de datos usados

Variables numéricas: edad, duracion_min, campana, contactos_previos, tasa_var_empleo, ipc, icc, euribor3m y num_empleados. Se usa correlación de Pearson, r entre -1 y 1.

Explicación detallada

El heatmap muestra relaciones lineales entre variables numéricas. Los colores cercanos a rojo indican correlación positiva; cercanos a azul, negativa. Los valores cercanos a 1 o -1 indican relación fuerte; valores cercanos a 0 indican poca relación lineal.

El hallazgo principal es la colinealidad entre variables macroeconómicas: tasa_var_empleo, euribor3m y num_empleados tienen r entre 0.91 y 0.97. Esto significa que se mueven juntas y describen el mismo ciclo económico.

La colinealidad importa porque en modelamiento puede duplicar información, dificultar interpretación de coeficientes o hacer que modelos lineales sean inestables. Por eso la presentación recomienda usar una variable representativa,

como euribor3m, en vez de todas sin control.

El icc, índice de confianza del consumidor, tiene relación más débil con Euribor, alrededor de 0.28, así que puede aportar información complementaria. Edad, duración y campaña casi no se relacionan linealmente entre sí, lo que indica que capturan dimensiones diferentes.

Resultado o lectura principal

Las variables macroeconómicas son valiosas, pero deben seleccionarse con cuidado por redundancia.

Qué decir si preguntan

Si preguntan por Pearson, responder que mide relación lineal y no captura todas las relaciones posibles; por eso se complementó con gráficos e interpretación.

Página 16: Conclusiones

Tipo de página
Síntesis de hallazgos y recomendaciones

Tipo de datos usados

No introduce gráficos nuevos. Resume patrones identificados en tasas, distribuciones y correlaciones.

Explicación detallada

Las conclusiones traducen el EDA en acciones. Priorizar clientes con historial se basa en tasas superiores al 60%. Limitar insistencia se basa en la caída de aceptación desde un contacto hasta más de diez. Planificar según tasas de interés se basa en la diferencia entre Euribor menor a 3% y mayor o igual a 3%.

También se recomienda mirar segmentos poco contactados que aceptan más: jubilados, estudiantes y clientes con estudios superiores. Esto no significa abandonar grupos tradicionales, sino revisar la asignación de esfuerzo.

Las precauciones son esenciales. Las relaciones son descriptivas, no causales. El periodo 2008-2010 está marcado por crisis financiera, por lo que los patrones económicos podrían no repetirse en otro periodo. Y la duración debe excluirse en modelamiento previo al contacto para evitar fuga de información.

Resultado o lectura principal

La presentación no se queda en describir gráficos; convierte los hallazgos en recomendaciones de segmentación, límites operativos y diseño futuro del modelo.

Qué decir si preguntan

Una buena frase de cierre: el EDA nos dice dónde mirar, qué variables cuidar y qué errores evitar antes de modelar.

Página 17: ¡Gracias!

Tipo de página
Cierre y ronda de preguntas

Tipo de datos usados

No contiene datos nuevos.

Explicación detallada

Esta página cierra la exposición y abre preguntas. Aunque parezca simple, es útil tener preparadas respuestas sobre decisiones críticas: unknown, pdays=999, duración, desbalance y causalidad.

El equipo debe sostener que el proyecto está en fase de EDA. Por eso las respuestas deben evitar prometer predicción o causalidad. La postura correcta es: encontramos asociaciones consistentes, justificamos limpieza y dejamos criterios para modelamiento futuro.

Resultado o lectura principal

El cierre debe reforzar que el análisis fue ordenado, reproducible y crítico.

Qué decir si preguntan

Si el profesor pregunta por limitaciones, mencionar ausencia de ID de cliente, periodo histórico específico, desbalance de clases y posible sesgo de selección de campaña.

Apéndice: respuestas de defensa rápidas

¿Por qué comparar tasas en lugar de conteos?

Porque la clase No es mucho más grande. Si usamos solo conteos, casi todos los grupos parecerán dominados por rechazos. La tasa estandariza por tamaño de grupo y permite comparar eficiencia relativa.

¿Por qué no eliminar todos los unknown?

Porque eliminar filas perdería información válida de otras variables. Además, en mora y educación el grupo unknown tiene comportamiento propio, así que tratarlo como categoría conserva una señal relevante.

¿Por qué no imputar pdays=999?

Porque 999 no es un dato faltante ni una cantidad real. Significa que el cliente nunca fue contactado antes. Imputarlo crearía un dato falso.

¿Por qué conservar atípicos?

Porque son plausibles y relevantes para el negocio. Una llamada de 80 minutos o un cliente mayor no son necesariamente errores; pueden representar casos extremos informativos.

¿Por qué duración no debería entrar a un modelo de priorización?

Porque se conoce después de llamar. Si queremos decidir a quién llamar, duration no existe todavía. Usarla sería fuga de información.

¿Qué variable macroeconómica elegirían para modelar?

Euribor3m es una buena candidata porque es interpretable, tiene fuerte asociación con aceptación y resume parte del ciclo económico. Pero se debe evitar meter todas las macro altamente colineales sin control.

¿Cuál es la principal recomendación de negocio?

No llamar masivamente sin segmentación. Priorizar historial, revisar canal, limitar insistencia y considerar el contexto económico.