

PROYECTO FINAL

Walter Quispe Vargas
Docente

Curso:
Introducción a Ciencia de Datos e Inteligencia Artificial

22 de Septiembre del 2026

**CIENCIA DE DATOS E
INTELIGENCIA ARTIFICIAL**

☎ (+51) 920000757
✉ wquispev@continental.edu.pe

Tabla de contenidos

1. RESUMEN	5
2. CONTEXTO DEL DATASET	5
2.1. Descripción del problema	5
2.2. Fuente del dataset	6
2.3. Objetivos del análisis	6
2.4. Variables	7
3. CARGA Y EXPLORACIÓN INICIAL	9
3.1. Librerías y funciones auxiliares	9
3.2. Dimensiones y estructura del dataset	11
3.3. Distribución de valores nulos	14
3.4. Balance de datos respecto a la aceptación de depósitos	16
4. PREPROCESAMIENTO DE LOS DATOS	18
4.1. Valores duplicados	18
4.2. Cambio de nombre de las columnas	19
4.3. Identificación y validación de los valores nulos	20
4.4. Tratamiento de los valores nulos	24
4.5. Revisión de días_previos	25
4.6. Transformación de tipos de dato	26
4.7. Enriquecimiento de los datos: creación de nuevas variables	27
5. ANÁLISIS EXPLORATORIO DE DATOS (EDA)	32
5.1. Análisis univariado	32
5.2. Análisis multivariado	44
6. CONCLUSIONES	65
6.1. Hallazgos a nivel univariado	65
6.2. Hallazgos a nivel multivariado	65
6.3. Colinealidad y posibles relaciones lineales	66
6.4. Variables clave que aportaron valor al análisis	66
6.5. Consideraciones finales	66

Listado de Tablas

1. Diferencias entre el estudio original y el dataset público.	6
--	---

2.	Variables del dataset, nombre usado en el análisis y tipo de dato.	7
3.	Primeros cinco registros del dataset original (filas y columnas transpuestas).	11
4.	Estadísticas descriptivas de las variables numéricas del dataset original.	13
5.	Estadísticas descriptivas de las variables categóricas del dataset original.	13
6.	Cantidad y porcentaje de valores desconocidos ('unknown') por variable.	15
7.	Frecuencia absoluta y relativa de la variable objetivo.	16
8.	Ejemplo de filas duplicadas (filas y columnas transpuestas).	18
9.	Tasa de aceptación del grupo con dato desconocido frente a la tasa general (11.27%).	21
10.	Tasa de aceptación por categoría en las variables con valores desconocidos.	22
11.	Tratamiento aplicado a cada variable con valores desconocidos.	24
12.	Nuevas variables creadas a partir de reglas simples.	27
13.	Tablas de frecuencia de las nuevas variables.	29
14.	Medidas de tendencia central de las variables numéricas.	32
15.	Medidas de dispersión de las variables numéricas.	33
16.	Límites de la regla 1.5·IQR y cantidad de valores atípicos por variable.	33
17.	Interpretación de las medidas de tendencia central y de dispersión.	34
18.	Resumen de cinco números y valores atípicos de las variables numéricas.	36
19.	Comparación entre media y mediana, y número de valores distintos por variable. . .	38
20.	Tabla de frecuencias de la edad por clases de 10 años.	38
21.	Tabla de frecuencias del número de contactos en la campaña (primeros diez valores).	39
22.	Tablas de frecuencia de las variables categóricas del perfil del cliente.	41
23.	Tablas de frecuencia de las variables categóricas de la campaña.	43
24.	Matriz de covarianza de las variables numéricas (la diagonal contiene las varianzas).	45
25.	Diez pares de variables con mayor correlación en valor absoluto.	47
26.	Pares con correlación absoluta mayor o igual a 0.8 (posible colinealidad).	47
27.	Medidas de posición de las variables numéricas según la suscripción.	49
28.	Contactos, tasa de aceptación y mediana del índice de confianza del consumidor por mes.	51
29.	Media, mediana y percentiles 10 y 90 según la suscripción.	53
30.	Tasa de aceptación según el nivel de la Euribor.	53
31.	Tasa de aceptación por categoría de las variables de la campaña.	56
32.	Tasa de aceptación por categoría de las variables del perfil del cliente.	58
33.	Correlación de Pearson y número de combinaciones distintas por par de indicadores.	61
34.	Duración media de la llamada y tasa de aceptación según el número de contactos en la campaña.	63
35.	Variables clave identificadas en el análisis exploratorio.	66

Listado de Figuras

1.	Porcentaje de valores desconocidos ('unknown') por variable.	15
2.	Distribución de la variable objetivo (y).	17
3.	Boxplots de las variables numéricas.	35
4.	Histogramas de las variables numéricas.	37
5.	Gráficos de barras de las variables categóricas del perfil del cliente.	41
6.	Gráficos de barras de las variables categóricas de la campaña y del historial de contacto.	43
7.	Mapa de calor de la correlación de Pearson entre variables numéricas.	46
8.	Boxplots comparativos de variables numéricas según la suscripción.	49
9.	Índice de confianza del consumidor según el mes de contacto.	51
10.	Histogramas de edad, duración y Euribor según la suscripción.	53
11.	Variables de la campaña según la suscripción.	56
12.	Variables del perfil del cliente según la suscripción.	58
13.	Diagramas de dispersión de los indicadores macroeconómicos.	61
14.	Diagramas de dispersión de variables que describen las llamadas.	63

1. RESUMEN

Título del trabajo: Análisis exploratorio de la aceptación de depósitos a plazo en campañas de telemarketing bancario.

Dataset: Bank Marketing, bank-additional-full.csv (UCI Machine Learning Repository).

Integrantes:

- Juan Aquino Espinoza
- Angel Mora
- Leonardo Cueva
- Adrian Varillas

Este informe presenta el entendimiento, la preparación y el análisis exploratorio de los datos de las campañas de telemarketing de un banco portugués, en las que se ofrecía a los clientes un depósito a plazo. El conjunto de datos tiene 41,188 contactos y solo el 11.27% terminó en una suscripción, lo que resume el problema de negocio: la mayor parte del esfuerzo de la campaña se invierte en clientes que no aceptan el producto.

En la preparación de los datos se eliminaron 12 filas duplicadas, se revisaron los valores "unknown" comparando su tasa de aceptación con la del resto de categorías (se conservaron como categoría propia en mora y educacion, y se imputaron con la moda en las demás) y se separó el valor 999 de dias_previos, que significa "nunca contactado" y no una cantidad de días. Además se crearon variables sencillas como la duración en minutos, tramos de duración, grupos de edad y un indicador de contacto previo.

El análisis exploratorio muestra que la aceptación es mucho mayor en los clientes con historial de contacto (63.83 % frente a 9.26 %), en los periodos con Euribor baja (24.46 % frente a 4.84 %), en clientes jóvenes y mayores de 65 años, en estudiantes y jubilados, y en contactos por celular. También muestra que insistir sobre un mismo cliente se asocia con una menor aceptación y que tres indicadores macroeconómicos (tasa_var_empleo, euribor3m y num_empleados) están fuertemente correlacionados entre sí. Todas estas relaciones son asociaciones descriptivas y no implican causalidad.

2. CONTEXTO DEL DATASET

2.1. Descripción del problema

En el sector bancario, las campañas de telemarketing para captar depósitos a plazo son una estrategia central para asegurar liquidez. El enfoque tradicional consiste en contactar de forma masiva a toda la base de clientes. Este enfoque es ineficiente: la mayoría de los clientes contactados no suscribe

el producto, lo que eleva el costo operativo de la campaña, satura los canales de atención y genera molestia en clientes que no tienen interés.

En términos generales, nuestro objetivo es conocer **qué características del cliente, de la forma de contacto y del entorno económico se asocian con una mayor aceptación del depósito a plazo**, de modo que la campaña pueda concentrar sus esfuerzos en los segmentos con mayor propensión.

Nota: un depósito a plazo (o depósito a plazo fijo) es un producto financiero en el cual un cliente entrega una cantidad de dinero al banco para que sea resguardada durante un periodo de tiempo preestablecido.

2.2. Fuente del dataset

El dataset proviene del **UCI Machine Learning Repository (Bank Marketing)** (Moro, Rita y Cortez 2014) y documenta campañas de telemarketing de una institución bancaria portuguesa. Para validar la fuente y los metadatos revisamos directamente el artículo donde se publicó (Moro, Cortez y Rita 2014).

Notamos que el estudio original y la versión pública del dataset no coinciden. Por ello, primero dejamos evidencia de las diferencias; **la consideración principal para este análisis es que rige la versión pública.**

Tabla 1: Diferencias entre el estudio original y el dataset público.

Métrica	Estudio original (Moro et al., 2014)	Dataset público (bank-additional-full.csv)
Registros	52,944 contactos	41,188 registros
Periodo	Mayo 2008 a junio 2013	Mayo 2008 a noviembre 2010
Variables	150 iniciales, reducidas a 22	20 variables de entrada + 1 variable objetivo
Motivo de la diferencia	Acceso a datos confidenciales del banco	Restricciones de privacidad

El universo de trabajo son las 41,188 filas y 21 columnas del archivo público. El estudio original se usa solo para dar contexto de negocio.

2.3. Objetivos del análisis

Este informe contiene nuestro entendimiento de los datos, su preparación y el análisis exploratorio. Específicamente, buscamos:

1. Describir el perfil de los clientes contactados y las características de las llamadas.

2. Identificar qué variables muestran diferencias en la tasa de aceptación entre grupos.
3. Detectar relaciones lineales y posibles problemas de colinealidad entre las variables numéricas.
4. Señalar las variables clave que aportan valor para predecir la aceptación de depósitos a plazo.

2.4. Variables

Tabla 2: Variables del dataset, nombre usado en el análisis y tipo de dato.

#	Variable original	Traducción usada	Descripción	Tipo
1	age	edad	Edad del cliente (años)	Cuantitativa discreta
2	job	empleo	Tipo de empleo	Cualitativa nominal
3	marital	estado_civil	Estado civil	Cualitativa nominal
4	education	educacion	Nivel educativo	Cualitativa ordinal
5	default	mora	¿Tiene crédito en mora?	Cualitativa nominal
6	housing	vivienda	¿Tiene préstamo hipotecario?	Cualitativa nominal
7	loan	prestamo	¿Tiene préstamo personal?	Cualitativa nominal
8	contact	tipo_contacto	Tipo de teléfono del contacto	Cualitativa nominal
9	month	mes	Mes del último contacto	Cualitativa ordinal
10	day_of_week	dia_semana	Día de la semana del último contacto	Cualitativa ordinal
11	duration	duracion	Duración del último contacto (segundos)	Cuantitativa continua
12	campaign	campana	Número de contactos en la campaña actual	Cuantitativa discreta
13	pdays	dias_previos	Días desde el último contacto de una campaña anterior (999 = nunca contactado)	Cuantitativa discreta

#	Variable	Traducción		Tipo
	original	usada	Descripción	
14	previous	contactos_previos	Número de contactos antes de esta campaña	Cuantitativa discreta
15	poutcome	resultado_previo	Resultado de la campaña anterior	Cualitativa nominal
16	emp.var.rate	tasa_var_emploi	Tasa de variación del empleo (trimestral)	Cuantitativa continua
17	cons.price.idx		Índice de precios al consumidor (mensual)	Cuantitativa continua
18	cons.conf.idx		Índice de confianza del consumidor (mensual)	Cuantitativa continua
19	euribor3m	euribor3m	Tasa Euribor a 3 meses (diaria)	Cuantitativa continua
20	nr.employed	num_employed	Número de empleados, indicador macroeconómico (trimestral)	Cuantitativa continua
21	y	suscribio	¿Suscribió un depósito a plazo? (variable objetivo)	Cualitativa nominal (binaria)

3. CARGA Y EXPLORACIÓN INICIAL

3.1. Librerías y funciones auxiliares

Se cargan las librerías del curso: **pandas** para la manipulación de datos, **seaborn** y **matplotlib** para los gráficos, y **numpy** solo para operaciones aritméticas de apoyo. También se define un conjunto de funciones auxiliares que se reutilizan a lo largo del análisis.

Nota: las siguientes secciones son solo observaciones; el tratamiento correspondiente se realiza en la sección de preprocesamiento.

```
import numpy as np
import pandas as pd
import matplotlib.pyplot as plt
import seaborn as sns

sns.set_theme(style="darkgrid")
pd.set_option("display.max_columns", 30)
pd.set_option("display.width", 140)
pd.set_option("display.float_format", "{:,.2f}".format)

RUTA_DATOS = "../bank-additional/bank-additional-full.csv"
```

```
# Funciones auxiliares
```

```
def mostrar_figura():
```

```
    plt.tight_layout()
```

```
    plt.show()
```

```
def limites_iqr(serie):
```

```
    q1 = serie.quantile(0.25)
```

```
    q3 = serie.quantile(0.75)
```

```
    iqr = q3 - q1
```

```
    return q1, q3, iqr, q1 - 1.5 * iqr, q3 + 1.5 * iqr
```

```
def resumen_numerico(datos, columnas):
```

```
filas = []
for col in columnas:
    serie = datos[col].dropna()
    q1, q3, iqr, lim_inf, lim_sup = limites_iqr(serie)
    atipicos = ((serie < lim_inf) | (serie > lim_sup)).sum()
    filas.append({
        "variable": col,
        "n": len(serie),
        "media": serie.mean(),
        "mediana": serie.median(),
        "moda": serie.mode()[0],
        "desv_est": serie.std(),
        "varianza": serie.var(),
        "minimo": serie.min(),
        "q1": q1,
        "q3": q3,
        "maximo": serie.max(),
        "rango": serie.max() - serie.min(),
        "iqr": iqr,
        "lim_inf_iqr": lim_inf,
        "lim_sup_iqr": lim_sup,
        "n_atipicos": atipicos,
        "pct_atipicos": 100 * atipicos / len(serie),
    })
return pd.DataFrame(filas).set_index("variable")

def tabla_frecuencias(serie):
    return pd.DataFrame({
        "frecuencia": serie.value_counts(),
        "porcentaje": 100 * serie.value_counts(normalize=True),
    })
```

```
def tasa_aceptacion(datos, columna, objetivo="suscribio", positivo="Sí"):
    conteo = pd.crosstab(datos[columna], datos[objetivo],
                          margins=True, margins_name="Total")
    porcentaje = 100 * pd.crosstab(datos[columna], datos[objetivo], normalize="index",
                                   margins=True, margins_name="Total")

    return pd.DataFrame({
        "contactos": conteo["Total"],
        "suscripciones": conteo[positivo],
        "tasa_aceptacion_%": porcentaje[positivo],
    })
```

3.2. Dimensiones y estructura del dataset

Comenzamos analizando los datos crudos: revisamos una muestra, los metadatos y un resumen estadístico descriptivo.

```
# Carga del dataset
df_original = pd.read_csv(RUTA_DATOS, sep=";")
print(f"Dimensiones: {df_original.shape[0]:,} filas x {df_original.shape[1]} columnas")
```

Dimensiones: 41,188 filas x 21 columnas

```
muestra = (df_original.head().T.rename(columns=lambda c: f"fila {c}"))
          .reset_index(names="variable").astype(str))
```

Tabla 3: Primeros cinco registros del dataset original (filas y columnas transpuestas).

variable	fila 0	fila 1	fila 2	fila 3	fila 4
age	56	57	37	40	56
job	housemaid	services	services	admin.	services
marital	married	married	married	married	married
education	basic.4y	high.school	high.school	basic.6y	high.school
default	no	unknown	no	no	no
housing	no	no	yes	no	no
loan	no	no	no	no	yes
contact	telephone	telephone	telephone	telephone	telephone
month	may	may	may	may	may
day_of_week	mon	mon	mon	mon	mon

duration	261	149	226	151	307
campaign	1	1	1	1	1
pdays	999	999	999	999	999
previous	0	0	0	0	0
poutcome	nonexistent	nonexistent	nonexistent	nonexistent	nonexistent
emp.var.rate	1.1	1.1	1.1	1.1	1.1
cons.price.idx	93.994	93.994	93.994	93.994	93.994
cons.conf.idx	-36.4	-36.4	-36.4	-36.4	-36.4
euribor3m	4.857	4.857	4.857	4.857	4.857
nr.employed	5191.0	5191.0	5191.0	5191.0	5191.0
y	no	no	no	no	no

```
# Metadata: nombres de columnas, tipos de dato y valores no nulos
df_original.info()
```

```
<class 'pandas.core.frame.DataFrame'>
```

```
RangeIndex: 41188 entries, 0 to 41187
```

```
Data columns (total 21 columns):
```

#	Column	Non-Null Count	Dtype
---	-----	-----	-----
0	age	41188 non-null	int64
1	job	41188 non-null	object
2	marital	41188 non-null	object
3	education	41188 non-null	object
4	default	41188 non-null	object
5	housing	41188 non-null	object
6	loan	41188 non-null	object
7	contact	41188 non-null	object
8	month	41188 non-null	object
9	day_of_week	41188 non-null	object
10	duration	41188 non-null	int64
11	campaign	41188 non-null	int64
12	pdays	41188 non-null	int64
13	previous	41188 non-null	int64
14	poutcome	41188 non-null	object
15	emp.var.rate	41188 non-null	float64

```

16  cons.price.idx  41188 non-null  float64
17  cons.conf.idx   41188 non-null  float64
18  euribor3m       41188 non-null  float64
19  nr.employed     41188 non-null  float64
20  y               41188 non-null  object

```

dtypes: float64(5), int64(5), object(11)

memory usage: 6.6+ MB

```

# Estadísticas de las variables numéricas y de las categóricas
describe_numericas = df_original.describe().T.reset_index(names="variable")
describe_categoricas = (df_original.describe(include="object").T
                        .reset_index(names="variable").astype(str))

```

Tabla 4: Estadísticas descriptivas de las variables numéricas del dataset original.

variable	count	mean	std	min	25 %	50 %	75 %	max
age	41,188	40.02	10.42	17.00	32.00	38.00	47.00	98.00
duration	41,188	258.29	259.28	0.00	102.00	180.00	319.00	4,918.00
campaign	41,188	2.57	2.77	1.00	1.00	2.00	3.00	56.00
pdays	41,188	962.48	186.91	0.00	999.00	999.00	999.00	999.00
previous	41,188	0.17	0.49	0.00	0.00	0.00	0.00	7.00
emp.var.rate	41,188	0.08	1.57	-3.40	-1.80	1.10	1.40	1.40
cons.price.idx	41,188	93.58	0.58	92.20	93.08	93.75	93.99	94.77
cons.conf.idx	41,188	-40.50	4.63	-50.80	-42.70	-41.80	-36.40	-26.90
euribor3m	41,188	3.62	1.73	0.63	1.34	4.86	4.96	5.04
nr.employed	41,188	5,167.04	72.25	4,963.60	5,099.10	5,191.00	5,228.10	5,228.10

Tabla 5: Estadísticas descriptivas de las variables categóricas del dataset original.

variable	count	unique	top	freq
job	41188	12	admin.	10422
marital	41188	4	married	24928
education	41188	8	university.degree	12168
default	41188	3	no	32588
housing	41188	3	yes	21576
loan	41188	3	no	33950
contact	41188	2	cellular	26144
month	41188	10	may	13769

day_of_week	41188	5	thu	8623
poutcome	41188	3	nonexistent	35563
y	41188	2	no	36548

Observaciones de la estructura del dataset

- El dataset contiene **41,188 registros y 21 columnas**, lo que coincide con la metadata oficial. Cada fila representa un contacto de la campaña con un cliente.
- Hay **10 variables numéricas** (5 enteras y 5 decimales) y **11 variables de tipo texto** (object), entre ellas la variable objetivo y. Ninguna columna presenta valores nulos explícitos.
- Las primeras estadísticas (Tabla 4) ya muestran rasgos que se analizan más adelante:
 - duration tiene una media de 258 segundos, pero un máximo de 4,918 (82 minutos): hay llamadas excepcionalmente largas.
 - En pdays la mediana y los cuartiles valen 999, lo que confirma que los clientes nunca contactados dominan la variable.
 - Los indicadores macroeconómicos (emp.var.rate, euribor3m, nr.employed) tienen una mediana muy superior a su media, señal de que los datos se concentran en periodos de tasas altas y de que existe un grupo de observaciones con valores bajos.
- En las categóricas (Tabla 5), las modas son: admin. en empleo, married en estado civil, university.degree en nivel de educación, cellular en tipo de contacto y may en mes. La moda de y es no, con 36,548 casos.

3.3. Distribución de valores nulos

La documentación del dataset indica que los atributos categóricos usan la etiqueta "unknown" cuando el dato no está disponible. Estos valores se consideran **nulos implícitos** y los cuantificamos por variable.

```
nulos = pd.DataFrame({
    "nulos_NaN": df_original.isnull().sum(),
    "nulos_unknown": (df_original == "unknown").sum(),
})

nulos["%_unknown"] = 100 * nulos["nulos_unknown"] / len(df_original)
nulos_unknown = (nulos[nulos["nulos_unknown"] > 0]
                  .sort_values("%_unknown", ascending=False))

print(f"Total de valores NaN: {nulos['nulos_NaN'].sum()}")
```

Total de valores NaN: 0

```
print(f"Columnas con unknown: {len(nulos_unknown)}")
```

Columnas con unknown: 6

```
tabla_unknown = nulos_unknown.reset_index(names="variable")
```

Tabla 6: Cantidad y porcentaje de valores desconocidos ('unknown') por variable.

variable	nulos_NaN	nulos_unknown	%_unknown
default	0	8,597	20.87
education	0	1,731	4.20
housing	0	990	2.40
loan	0	990	2.40
job	0	330	0.80
marital	0	80	0.19

```
plt.figure(figsize=(9, 4.5))
ax = sns.barplot(x=nulos_unknown.index, y=nulos_unknown["%_unknown"], color="steelblue")
ax.bar_label(ax.containers[0], fmt="%.2f%%")
plt.title("Porcentaje de valores desconocidos ('unknown') por variable")
plt.xlabel("Variable")
plt.ylabel("Porcentaje de registros (%)")
mostrar_figura()
```




Figura 1: Porcentaje de valores desconocidos ('unknown') por variable.

Observaciones de valores desconocidos

Hay seis variables categóricas con valores nulos (Figura 1):

- `default` (mora) concentra el **20.87%** de nulos. Es un volumen demasiado grande para eliminar esas filas sin perder una quinta parte de la muestra.
- `education` presenta un 4.20% de desconocidos, `housing` y `loan` un 2.40% cada una, y `job` y `marital` están por debajo del 1%.
- La calidad del atributo de mora (`default`) es la más afectada y, dado que es de los más relevantes en banca, realizaremos un tratamiento adicional en la sección de preprocesamiento evaluando su relación con la aceptación.

Note que la cantidad de nulos coincide entre `housing` y `loan`. Esto amerita revisar si el grupo de nulos en ambas variables es el mismo o es distinto, lo que queda pendiente para la sección de identificación y validación de nulos.

3.4. Balance de datos respecto a la aceptación de depósitos

Revisamos la proporción de clientes que suscribieron el depósito para evitar sesgos en el análisis por posibles desbalances.

```
balance = tabla_frecuencias(df_original["y"])
ratio = balance.loc["no", "frecuencia"] / balance.loc["yes", "frecuencia"]
print(f"Ratio de desbalance: 1 : {ratio:.2f}")
```

Ratio de desbalance: 1 : 7.88

```
tabla_balance = balance.reset_index(names="y")
```

Tabla 7: Frecuencia absoluta y relativa de la variable objetivo.

y	frecuencia	porcentaje
no	36,548	88.73
yes	4,640	11.27

```
plt.figure(figsize=(6, 4.5))
ax = sns.countplot(x=df_original["y"], order=["no", "yes"], color="steelblue")
ax.bar_label(ax.containers[0], fmt="{:,}.0f")
plt.title("Distribución de la variable objetivo (y)")
plt.xlabel("¿Suscribió un depósito a plazo?")
plt.ylabel("Número de clientes")
mostrar_figura()
```




Figura 2: *Distribución de la variable objetivo (y).*

Observaciones del balance de datos

- Solo el **11.27%** de los clientes contactados suscribió el depósito (4,640 casos), frente a un **88.73%** que no lo hizo (36,548 casos). El ratio es **1 : 7.88**: por cada suscripción hay casi ocho contactos sin éxito (Figura 2).
- Esta cifra cuantifica el problema de negocio: la mayor parte del esfuerzo de la campaña se invierte en clientes que no convierten.
- Esto implica que los conteos siempre favorecerán al grupo de clientes que rechazan. Por ello, en el análisis multivariado conviene usar **tasas de aceptación** y no conteos.

4. PREPROCESAMIENTO DE LOS DATOS

En esta etapa hacemos el tratamiento correspondiente según lo observado en la sección anterior (limpieza de duplicados y de valores faltantes). Se trabaja sobre una copia para conservar el dataset original.

4.1. Valores duplicados

```
df = df_original.copy()

n_duplicados = df.duplicated().sum()
print(f"Filas completamente duplicadas: {n_duplicados} "
      f"({100 * n_duplicados / len(df):.3f}% del total)")
```

Filas completamente duplicadas: 12 (0.029% del total)

```
ejemplo_duplicados = (df[df.duplicated(keep=False)]
                      .sort_values(["age", "duration"])
                      .head(6).T.rename(columns=lambda c: f"fila {c}")
                      .reset_index(names="variable").astype(str))
```

Tabla 8: Ejemplo de filas duplicadas (filas y columnas transpuestas).

variable	fila 28476	fila 28477	fila 14155	fila 14234	fila 18464	fila 18464
age	24	24	27	27	32	32
job	services	services	technician	technician	technician	technician
marital	single	single	single	single	single	single
education	high.school	high.school	professional.course	professional.course	professional.course	professional.course
default	no	no	no	no	no	no
housing	yes	yes	no	no	yes	yes
loan	no	no	no	no	no	no
contact	cellular	cellular	cellular	cellular	cellular	cellular
month	apr	apr	jul	jul	jul	jul
day_of_week	tue	tue	mon	mon	thu	thu
duration	114	114	331	331	128	128
campaign	1	1	2	2	1	1
pdays	999	999	999	999	999	999
previous	0	0	0	0	0	0
poutcome	nonexistent	nonexistent	nonexistent	nonexistent	nonexistent	nonexistent

emp.var.rate	-1.8	-1.8	1.4	1.4	1.4	1.4
cons.price.idx	93.075	93.075	93.918	93.918	93.918	93.918
cons.conf.idx	-47.1	-47.1	-42.7	-42.7	-42.7	-42.7
euribor3m	1.423	1.423	4.962	4.962	4.968	4.968
nr.employed	5099.1	5099.1	5228.1	5228.1	5228.1	5228.1
y	no	no	no	no	no	no

```
filas_antes = len(df)
df = df.drop_duplicates().reset_index(drop=True)
print(f"Filas antes: {filas_antes:,} | Filas después: {len(df):,} | "
      f"Eliminadas: {filas_antes - len(df):,}")
```

Filas antes: 41,188 | Filas después: 41,176 | Eliminadas: 12

Observaciones sobre duplicados

- Se encontraron **12 filas idénticas** en las 21 variables, incluidas la duración exacta de la llamada, el día, el mes y los cinco indicadores macroeconómicos. Representan apenas el **0.029%** del total.
- El dataset no tiene un identificador de cliente, por lo que no es posible confirmar si son dos personas distintas con características idénticas. Sin embargo, coincidir en todos los atributos, incluida la duración al segundo, es muy improbable y apunta a un error de registro.

Se decidió **eliminarlos**.

Justificación: la eliminación no altera las distribuciones, y mantenerlos contaría dos veces el mismo contacto. El dataset de trabajo queda con **41,176 registros**.

4.2. Cambio de nombre de las columnas

Las columnas se renombran al español con nombres descriptivos y sin puntos (ver Tabla 2). Esto facilita la lectura del análisis y evita errores al referirse a nombres como `emp.var.rate`.

```
nombres_columnas = {
    "age": "edad",
    "job": "empleo",
    "marital": "estado_civil",
    "education": "educacion",
    "default": "mora",
    "housing": "vivienda",
```

```

"loan": "prestamo",
"contact": "tipo_contacto",
"month": "mes",
"day_of_week": "dia_semana",
"duration": "duracion",
"campaign": "campana",
"pdays": "dias_previos",
"previous": "contactos_previos",
"poutcome": "resultado_previo",
"emp.var.rate": "tasa_var_empleo",
"cons.price.idx": "ipc",
"cons.conf.idx": "icc",
"euribor3m": "euribor3m",
"nr.employed": "num_empleados",
"y": "suscribio",
}
df = df.rename(columns=nombres_columnas)

for i in range(0, len(df.columns), 6):
    print(", ".join(df.columns[i:i + 6]))

```

```

edad, empleo, estado_civil, educacion, mora, vivienda
prestamo, tipo_contacto, mes, dia_semana, duracion, campana
dias_previos, contactos_previos, resultado_previo, tasa_var_empleo, ipc, icc
euribor3m, num_empleados, suscribio

```

4.3. Identificación y validación de los valores nulos

En el contexto bancario, datos como la mora o los préstamos provienen de centrales de riesgo y de los sistemas del banco (en Perú, la SBS). Por eso, para decidir qué hacer con los valores nulos aplicamos una **validación descriptiva**: comparamos la tasa de aceptación en el grupo de nulos con la tasa general y con las tasas de las categorías conocidas.

La idea es determinar si el grupo de clientes con dato desconocido contiene información útil sobre los clientes que aceptaron el depósito o si solamente es ruido. Si es lo primero, añadimos una categoría nueva; si no, imputamos con la moda para no alterar la distribución.

Adicionalmente, como encontramos la misma cantidad de nulos en vivienda (housing) y préstamo (loan), revisamos si los nulos de ambas variables corresponden a los mismos registros.

```
columnas_unknown = ["mora", "educacion", "vivienda", "prestamo", "empleo", "estado_civil"]
tasa_general = 100 * (df["suscribio"] == "yes").mean()
print(f"Tasa general de aceptación: {tasa_general:.2f}%")
```

Tasa general de aceptación: 11.27%

```
filas = []
detalle = []
for col in columnas_unknown:
    tasas = tasa_aceptacion(df, col, positivo="yes")
    tasa_nulos = tasas.loc["unknown", "tasa_aceptacion_%"]
    filas.append({
        "variable": col,
        "nulos": (df[col] == "unknown").sum(),
        "%_nulos": 100 * (df[col] == "unknown").mean(),
        "tasa_nulos_%": tasa_nulos,
        "diferencia_vs_general": tasa_nulos - tasa_general,
    })
    detalle.append(tasas.drop("Total").reset_index(names="categoria")
                  .assign(variable=col))

validacion_unknown = pd.DataFrame(filas)
detalle_unknown = pd.concat(detalle)[["variable", "categoria", "contactos",
                                       "suscripciones", "tasa_aceptacion_%"]]

mismas_filas = ((df["vivienda"] == "unknown") == (df["prestamo"] == "unknown")).all()
print(f"Los nulos de vivienda y préstamo son las mismas filas: {mismas_filas}")
```

Los nulos de vivienda y préstamo son las mismas filas: True

Tabla 9: Tasa de aceptación del grupo con dato desconocido frente a la tasa general (11.27%).

variable	nulos	%_nulos	tasa_nulos_%	diferencia_vs_general
mora	8,596	20.88	5.15	-6.11
educacion	1,730	4.20	14.51	3.24

vivienda	990	2.40	10.81	-0.46
prestamo	990	2.40	10.81	-0.46
empleo	330	0.80	11.21	-0.05
estado_civil	80	0.19	15.00	3.73

Tabla 10: Tasa de aceptación por categoría en las variables con valores desconocidos.

variable	categoría	contactos	suscripciones	tasa_aceptacion_%
mora	no	32,577	4,196	12.88
mora	unknown	8,596	443	5.15
mora	yes	3	0	0.00
educacion	basic.4y	4,176	428	10.25
educacion	basic.6y	2,291	188	8.21
educacion	basic.9y	6,045	473	7.82
educacion	high.school	9,512	1,031	10.84
educacion	illiterate	18	4	22.22
educacion	professional.course	5,240	595	11.35
educacion	university.degree	12,164	1,669	13.72
educacion	unknown	1,730	251	14.51
vivienda	no	18,615	2,025	10.88
vivienda	unknown	990	107	10.81
vivienda	yes	21,571	2,507	11.62
prestamo	no	33,938	3,849	11.34
prestamo	unknown	990	107	10.81
prestamo	yes	6,248	683	10.93
empleo	admin.	10,419	1,351	12.97
empleo	blue-collar	9,253	638	6.90
empleo	entrepreneur	1,456	124	8.52
empleo	housemaid	1,060	106	10.00
empleo	management	2,924	328	11.22
empleo	retired	1,718	434	25.26
empleo	self-employed	1,421	149	10.49
empleo	services	3,967	323	8.14
empleo	student	875	275	31.43
empleo	technician	6,739	730	10.83
empleo	unemployed	1,014	144	14.20
empleo	unknown	330	37	11.21

estado_civil	divorced	4,611	476	10.32
estado_civil	married	24,921	2,531	10.16
estado_civil	single	11,564	1,620	14.01
estado_civil	unknown	80	12	15.00

Análisis de los valores nulos

Evaluamos la tasa de aceptación de depósitos entre el grupo de nulos y el resto de categorías en las variables que contenían nulos (todas categóricas). En las variables donde el grupo de nulos no muestra un comportamiento distinto, imputamos con la moda. Si se observa una diferencia destacable entre el grupo con nulos y el resto de categorías, imputamos con una nueva clase para preservar ese comportamiento distinto (Tabla 9 y Tabla 10).

- En **mora** hay 8,596 nulos, de los cuales el **5.15 %** suscribió, menos de la mitad que cuando sí se conoce la mora (12.88 %). La diferencia es de -6.11 puntos porcentuales frente a la tasa general y el grupo es grande. **En el grupo con mora desconocida el porcentaje de aceptación cambia notablemente, lo que indica un segmento con menor propensión; lo conservaremos como una nueva categoría.** Posiblemente se trata de clientes sin historial en la central de riesgos.
- En **educacion** el grupo con nulos (1,730 clientes) tiene una tasa de aceptación de **14.51 %**, **que supera a todas las demás categorías con un volumen relevante, por lo que lo asumimos como un nuevo segmento.** La categoría illiterate sí supera la tasa de los nulos (22.22 %), pero apenas tiene 18 clientes, por lo que no la consideramos una diferencia notable.
- En **vivienda y prestamo** los desconocidos (10.81 %) están prácticamente en el mismo rango de las categorías conocidas (10.88 % a 11.62 %) y de la tasa general. Además, son **los mismos 990 registros** en ambas variables, lo que sugiere una falla puntual de registro y no un segmento de clientes; por ello imputamos con la moda.
- En **empleo** la tasa de aceptación del grupo con nulos es 11.21 %, casi idéntica a la general (difiere solo en -0.05 puntos) y afecta al 0.80 % de los registros, por lo que es apropiado imputar con la moda.
- En **estado_civil** la tasa de los desconocidos (15.00 %) es relativamente alta, pero se calcula sobre solo **80 clientes** (0.19 %). Con tan pocos casos, una diferencia de 12 suscripciones cambia la tasa en varios puntos, por lo que no se considera evidencia de un segmento propio y se imputa con la moda.

4.4. Tratamiento de los valores nulos

Con base en la validación anterior, primero se convierten los "unknown" en valores nulos (NaN), de modo que queden identificados de forma explícita, y luego se tratan según la regla de decisión de la Tabla 11.

Tabla 11: *Tratamiento aplicado a cada variable con valores desconocidos.*

Variable	Tratamiento	Justificación
mora, educacion	Se conservan como categoría "desconocido"	Su tasa de aceptación difiere de la de las categorías conocidas: la ausencia del dato describe un segmento de clientes.
empleo, estado_civil, vivienda, prestamo	Imputación con la moda	Su tasa de aceptación es similar a la del resto y afectan a pocos registros, por lo que la moda no distorsiona la distribución.

Se prefiere la imputación antes que la eliminación de filas para no perder los datos válidos del resto de variables de esos clientes.

```
# Pasamos los valores "unknown" a NaN
df = df.replace("unknown", np.nan)
print("Valores nulos por variable después de la conversión:")
```

Valores nulos por variable después de la conversión:

```
print(df.isnull().sum()[df.isnull().sum() > 0], "\n")
```

```
empleo          330
estado_civil     80
educacion       1730
mora            8596
vivienda         990
prestamo         990
dtype: int64
```

```
for col in ["mora", "educacion"]:
    df[col] = df[col].fillna("desconocido")
```

```
for col in ["empleo", "estado_civil", "vivienda", "prestamo"]:
    moda = df[col].mode()[0]
    n_imputados = df[col].isnull().sum()
    df[col] = df[col].fillna(modas)
    print(f"{col:<13} -> {n_imputados:>4} valores imputados con la moda '{moda}'")
```

```
empleo          -> 330 valores imputados con la moda 'admin.'
estado_civil    -> 80 valores imputados con la moda 'married'
vivienda        -> 990 valores imputados con la moda 'yes'
prestamo        -> 990 valores imputados con la moda 'no'
```

```
print(f"\nValores nulos restantes en el dataset: {df.isnull().sum().sum()}")
```

Valores nulos restantes en el dataset: 0

4.5. Revisión de días_previos

La variable `días_previos` usa el valor **999** para indicar que el cliente **nunca fue contactado** en una campaña anterior. Este valor no es una cantidad real de días: si se trata como número, eleva de forma artificial la media y oculta la distribución de los clientes que sí fueron contactados.

Por lo tanto, creamos una nueva variable `días_desde_contacto`, igual a `días_previos` pero con NaN cuando el valor es 999. Estos nulos **no se imputan**, porque representan un dato que no aplica (el contacto nunca ocurrió) y cualquier valor inventado sería engañoso. La información de si hubo o no un contacto previo se conserva en una nueva variable categórica (sección de creación de nuevas variables).

```
nunca_contactados = (df["días_previos"] == 999).sum()
print(f"Registros con días_previos = 999: {nunca_contactados}, { "
      f"({100 * nunca_contactados / len(df):.2f}%)")
```

Registros con días_previos = 999: 39,661 (96.32%)

```
df["días_desde_contacto"] = df["días_previos"].where(df["días_previos"] != 999)
print(f"Registros con días reales desde el último contacto: "
      f"{df['días_desde_contacto'].notnull().sum():,}")
```

Registros con días reales desde el último contacto: 1,515

```
print(f"Media de dias_previos con el valor 999: {df['dias_previos'].mean():.2f}")
```

Media de dias_previos con el valor 999: 962.46

```
print(f"Media de dias_desde_contacto sin el 999: {df['dias_desde_contacto'].mean():.2f}")
```

Media de dias_desde_contacto sin el 999: 6.01

4.6. Transformación de tipos de dato

Las variables categóricas se convierten al tipo category. En las variables ordinales (educacion, mes, dia_semana) se define el orden natural de sus niveles, lo que permite que tablas y gráficos respeten ese orden. La variable objetivo se recodifica como "Sí" / "No" para facilitar la lectura.

```
df["suscribio"] = df["suscribio"].map({"yes": "Sí", "no": "No"})
orden_educacion = ["illiterate", "basic.4y", "basic.6y", "basic.9y", "high.school",
                    "professional.course", "university.degree", "desconocido"]
orden_meses = ["mar", "apr", "may", "jun", "jul", "aug", "sep", "oct", "nov", "dec"]
orden_dias = ["mon", "tue", "wed", "thu", "fri"]

df["educacion"] = pd.Categorical(df["educacion"], categories=orden_educacion, ordered=True)
df["mes"] = pd.Categorical(df["mes"], categories=orden_meses, ordered=True)
df["dia_semana"] = pd.Categorical(df["dia_semana"], categories=orden_dias, ordered=True)

for col in ["empleo", "estado_civil", "mora", "vivienda", "prestamo",
            "tipo_contacto", "resultado_previo", "suscribio"]:
    df[col] = df[col].astype("category")

print(df.dtypes)
```

edad	int64
empleo	category
estado_civil	category
educacion	category
mora	category
vivienda	category
prestamo	category
tipo_contacto	category
mes	category

```

dia_semana          category
duracion            int64
campana             int64
dias_previos        int64
contactos_previos   int64
resultado_previo    category
tasa_var_empleo     float64
ipc                 float64
icc                 float64
euribor3m           float64
num_empleados       float64
suscribio           category
dias_desde_contacto float64
dtype: object

```

4.7. Enriquecimiento de los datos: creación de nuevas variables

Se crean nuevas variables derivadas de acuerdo con los objetivos propuestos, mediante reglas simples que facilitan la interpretación de los datos y permiten identificar patrones relevantes para el negocio (Tabla 12).

Tabla 12: Nuevas variables creadas a partir de reglas simples.

Nueva variable	Regla	Propósito
duracion_min	<code>duracion / 60</code>	Expresar la duración de la llamada en minutos, una unidad más intuitiva.
tramo_duracion	Intervalos de minutos con <code>pd.cut</code>	Identificar a partir de qué duración aumenta la aceptación.
grupo_etario	Intervalos de edad con <code>pd.cut</code>	Perfilar etapas de vida del cliente.
contacto_previo	"Sí" si <code>dias_previos</code> es distinto de 999	Distinguir a los clientes con historial de contacto.

Justificación

- **duracion_min:** convertir la duración de las llamadas a minutos facilita su interpretación y permite describir las características del contacto en una unidad más intuitiva.
- **tramo_duracion:** agrupar las llamadas según su duración permite comparar las tasas de aceptación entre intervalos e identificar posibles patrones de conversión asociados al tiempo de contacto.
- **grupo_etario:** clasificar a los clientes en grupos de edad facilita la descripción de su perfil y la comparación de las tasas de aceptación entre distintas etapas de vida.
- **contacto_previo:** distinguir a los clientes que tuvieron contactos anteriores de aquellos sin contacto previo permite evaluar si el historial de interacción se asocia con diferencias en la aceptación del depósito a plazo.

```
# Duración en minutos
df["duracion_min"] = df["duracion"] / 60

# Tramos de duración de la llamada (minutos)
df["tramo_duracion"] = pd.cut(
    df["duracion_min"],
    bins=[0, 1, 2, 3, 5, 10, df["duracion_min"].max()],
    labels=["0-1 min", "1-2 min", "2-3 min", "3-5 min", "5-10 min", "más de 10 min"],
    include_lowest=True,
)

# Grupos etarios
df["grupo_etario"] = pd.cut(
    df["edad"],
    bins=[16, 24, 34, 44, 54, 64, df["edad"].max()],
    labels=["17-24", "25-34", "35-44", "45-54", "55-64", "65 o más"],
)

# Indicador de contacto en campañas anteriores
df["contacto_previo"] = np.where(df["dias_previos"] != 999, "Sí", "No")
df["contacto_previo"] = df["contacto_previo"].astype("category")

frecuencias_nuevas = pd.concat([
```

```
tabla_frecuencias(df[col]).sort_index().reset_index(names="categoria")
.assign(variable=col)
for col in ["tramo_duracion", "grupo_etario", "contacto_previo"]
][["variable", "categoria", "frecuencia", "porcentaje"]]
```

Tabla 13: *Tablas de frecuencia de las nuevas variables.*

variable	categoria	frecuencia	porcentaje
tramo_duracion	0-1 min	4,284	10.40
tramo_duracion	1-2 min	8,628	20.95
tramo_duracion	2-3 min	7,784	18.90
tramo_duracion	3-5 min	9,278	22.53
tramo_duracion	5-10 min	7,738	18.79
tramo_duracion	más de 10 min	3,464	8.41
grupo_etario	17-24	1,067	2.59
grupo_etario	25-34	13,684	33.23
grupo_etario	35-44	13,495	32.77
grupo_etario	45-54	8,702	21.13
grupo_etario	55-64	3,566	8.66
grupo_etario	65 o más	662	1.61
contacto_previo	No	39,661	96.32
contacto_previo	Sí	1,515	3.68

```
print(f"Dimensiones finales: {df.shape[0]:,} filas x {df.shape[1]} columnas\n")
```

Dimensiones finales: 41,176 filas x 26 columnas

```
df.info()
```

```
<class 'pandas.core.frame.DataFrame'>
```

```
RangeIndex: 41176 entries, 0 to 41175
```

```
Data columns (total 26 columns):
```

#	Column	Non-Null Count	Dtype
---	-----	-----	-----
0	edad	41176 non-null	int64
1	empleo	41176 non-null	category
2	estado_civil	41176 non-null	category
3	educacion	41176 non-null	category

```

4  mora                41176 non-null  category
5  vivienda             41176 non-null  category
6  prestamo             41176 non-null  category
7  tipo_contacto        41176 non-null  category
8  mes                  41176 non-null  category
9  dia_semana           41176 non-null  category
10 duracion             41176 non-null  int64
11 campana             41176 non-null  int64
12 dias_previos        41176 non-null  int64
13 contactos_previos   41176 non-null  int64
14 resultado_previo    41176 non-null  category
15 tasa_var_empleo     41176 non-null  float64
16 ipc                 41176 non-null  float64
17 icc                 41176 non-null  float64
18 euribor3m           41176 non-null  float64
19 num_empleados       41176 non-null  float64
20 suscribio           41176 non-null  category
21 dias_desde_contacto 1515 non-null  float64
22 duracion_min        41176 non-null  float64
23 tramo_duracion       41176 non-null  category
24 grupo_etario        41176 non-null  category
25 contacto_previo     41176 non-null  category

```

dtypes: category(14), float64(7), int64(5)

memory usage: 4.3 MB

Resumen del preprocesamiento

- **Duplicados:** se eliminaron 12 filas; el dataset pasó de 41,188 a **41,176 registros**.
- **Valores nulos:** los "unknown" se convirtieron en NaN y se trataron según la validación. mora y educacion conservan la categoría "desconocido". En las otras cuatro variables se imputó la moda: admin. (330 valores en empleo), married (80 en estado_civil), yes (990 en vivienda) y no (990 en prestamo). Tras este paso no quedan nulos en las variables originales.
- **Días previos:** el 96.32% de los clientes nunca había sido contactado (dias_previos = 999). Al separar ese valor, la media de días desde el último contacto pasa de un engañoso **962.46** a un valor real de **6.01 días**, calculado sobre los 1,515 clientes con historial. Los únicos nulos del dataset final (39,661 en dias_desde_contacto) son intencionales: el dato no aplica.

- **Tipos de dato:** 14 variables quedaron como category; educacion, mes y dia_semana tienen un orden definido.
- **Nuevas variables** (Tabla 13):
 - Por duración, el tramo más frecuente es “3-5 min” (22.53 %) y solo el 8.41 % de las llamadas supera los 10 minutos.
 - Los grupos etarios dominantes son 25-34 (33.23 %) y 35-44 (32.77 %).
 - Solo el 3.68 % de los clientes tiene contacto previo.
- El dataset preprocesado tiene **41,176 filas y 26 columnas**.

5. ANÁLISIS EXPLORATORIO DE DATOS (EDA)

Las variables se agrupan en tres conjuntos:

- **Numéricas:** edad, duracion_min, campana, dias_desde_contacto, contactos_previos, tasa_var_empleo, ipc, icc, euribor3m y num_empleados.
- **Catógicas del perfil del cliente:** empleo, estado_civil, educacion, mora, vivienda, prestamo y grupo_etario.
- **Catógicas de la campaña:** tipo_contacto, mes, dia_semana, resultado_previo y contacto_previo.

```
variables_numericas = ["edad", "duracion_min", "campana", "dias_desde_contacto",  
                        "contactos_previos", "tasa_var_empleo", "ipc", "icc",  
                        "euribor3m", "num_empleados"]  
  
variables_categoricas_perfil = ["empleo", "estado_civil", "educacion", "mora",  
                                "vivienda", "prestamo", "grupo_etario"]  
variables_categoricas_campana = ["tipo_contacto", "mes", "dia_semana",  
                                 "resultado_previo", "contacto_previo"]
```

Nota: dias_desde_contacto solo tiene valores para los clientes contactados en campañas anteriores, por lo que sus estadísticas se calculan sobre ese subconjunto. La duración se analiza en minutos (duracion_min).

5.1. Análisis univariado

5.1.1. Medidas de tendencia central y de dispersión

Nota: para cada variable, los valores fuera del rango $[Q1 - 1.5 \cdot IQR, Q3 + 1.5 \cdot IQR]$ se consideran atípicos, según la regla del boxplot.

```
resumen = resumen_numerico(df, variables_numericas)  
  
tendencia_central = resumen[["n", "media", "mediana", "moda"]].reset_index()  
dispersion = resumen[["desv_est", "varianza", "minimo", "q1", "q3",  
                       "maximo", "rango", "iqr"]].reset_index()  
atipicos = resumen[["lim_inf_iqr", "lim_sup_iqr", "n_atipicos",  
                    "pct_atipicos"]].reset_index()
```

Tabla 14: Medidas de tendencia central de las variables numéricas.

variable	n	media	mediana	moda
edad	41,176	40.02	38.00	31.00
duracion_min	41,176	4.31	3.00	1.42
campana	41,176	2.57	2.00	1.00
dias_desde_contacto	1,515	6.01	6.00	3.00
contactos_previos	41,176	0.17	0.00	0.00
tasa_var_empleo	41,176	0.08	1.10	1.40
ipc	41,176	93.58	93.75	93.99
icc	41,176	-40.50	-41.80	-36.40
euribor3m	41,176	3.62	4.86	4.86
num_empleados	41,176	5,167.03	5,191.00	5,228.10

Tabla 15: Medidas de dispersión de las variables numéricas.

variable	desv_est	varianza	minimo	q1	q3	maximo	rango	iqr
edad	10.42	108.59	17.00	32.00	47.00	98.00	81.00	15.00
duracion_min	4.32	18.68	0.00	1.70	5.32	81.97	81.97	3.62
campana	2.77	7.67	1.00	1.00	3.00	56.00	55.00	2.00
dias_desde_contacto	3.82	14.63	0.00	3.00	7.00	27.00	27.00	4.00
contactos_previos	0.49	0.24	0.00	0.00	0.00	7.00	7.00	0.00
tasa_var_empleo	1.57	2.47	-3.40	-1.80	1.40	1.40	4.80	3.20
ipc	0.58	0.34	92.20	93.08	93.99	94.77	2.57	0.92
icc	4.63	21.42	-50.80	-42.70	-36.40	-26.90	23.90	6.30
euribor3m	1.73	3.01	0.63	1.34	4.96	5.04	4.41	3.62
num_empleados	72.25	5,220.26	4,963.60	5,099.10	5,228.10	5,228.10	264.50	129.00

Tabla 16: Límites de la regla $1.5 \cdot IQR$ y cantidad de valores atípicos por variable.

variable	lim_inf_iqr	lim_sup_iqr	n_atipicos	pct_atipicos
edad	9.50	69.50	468	1.14
duracion_min	-3.72	10.74	2,963	7.20
campana	-2.00	6.00	2,406	5.84
dias_desde_contacto	-3.00	13.00	82	5.41
contactos_previos	0.00	0.00	5,625	13.66
tasa_var_empleo	-6.60	6.20	0	0.00
ipc	91.70	95.37	0	0.00
icc	-52.15	-26.95	446	1.08

euribor3m	-4.08	10.39	0	0.00
num_empleados	4,905.60	5,421.60	0	0.00

Observaciones de la tendencia central y la dispersión

Tabla 17: Interpretación de las medidas de tendencia central y de dispersión.

Variable	Hallazgos
edad	Media de 40.02 años, mediana de 38 y moda de 31: la media supera a la mediana por la presencia de clientes mayores. La desviación estándar es de 10.42 años y el 50 % central está entre 32 y 47 años (IQR = 15). Hay 468 atípicos (1.14%), todos por encima de 69.5 años.
duracion_min	La media de 4.31 minutos supera a la mediana de 3.00: la mayoría de llamadas es corta, pero hay llamadas muy largas. El rango (81.97 min) es enorme frente al IQR (3.62 min). El 7.20 % de las llamadas (2,963) supera los 10.74 minutos y se considera atípica.
campana	La moda es 1 contacto y la mediana, 2. La media (2.57) se eleva por un grupo reducido de clientes contactados de forma reiterada, hasta 56 veces. El 5.84 % (2,406 clientes) recibió más de 6 contactos; este sería el segmento de insistencia excesiva .
dias_desde_contacto	Para los 1,515 clientes con historial, la media (6.01) y la mediana (6) casi coinciden, con un IQR de 3 a 7 días. Los contactos previos suelen ser recientes, alrededor de una semana antes. El 5.41 % supera los 13 días.
contactos_previos	La media es 0.17 y la moda, 0. El IQR es 0 porque más del 75 % de los clientes nunca fue contactado; por eso, según el IQR, cualquier cliente con al menos un contacto previo (13.66 %) es atípico. En este caso no se trata de errores, sino del grupo minoritario con historial.
tasa_var_empleo	Varía en un rango de -3.4 a 1.4, sin atípicos. La mediana (1.10) es muy superior a la media (0.08): indica la existencia de periodos de crecimiento y de decrecimiento del empleo.
ipc	Tiene muy poca dispersión (desviación estándar de 0.58 sobre una media de 93.58; rango de 2.57 puntos). Es la variable más estable del grupo.
icc	Media de -40.50 y mediana de -41.80: la confianza del consumidor fue negativa en todo el periodo, reflejo del contexto de crisis. Hay 446 atípicos (1.08 %) en el extremo menos pesimista (-26.9).

Variable	Hallazgos
euribor3m	La mediana (4.86 %) está muy por encima de la media (3.62 %) y la desviación estándar es alta (1.73) para una tasa de interés. Esto evidencia dos contextos distintos: tasas previas a la crisis cercanas a 5 % y tasas posteriores cercanas a 1 %.
num_empleados	Media de 5,167 y mediana de 5,191, con un IQR de 129. No presenta atípicos, pero su distribución está concentrada en un rango pequeño de valores.

En síntesis, las variables que describen las llamadas (duracion_min, campana, contactos_previos) presentan la mayor dispersión respecto al resto y concentran los valores extremos. Las variables macroeconómicas no tienen atípicos, pero la gran diferencia entre su media y su mediana indica que sus distribuciones están cargadas hacia un lado.

5.1.2. Boxplots de las variables numéricas

Validamos el análisis de dispersión previo visualizando los boxplots respectivos (Figura 3).

```
fig, ejes = plt.subplots(2, 5, figsize=(20, 8))
for eje, col in zip(ejes.flatten(), variables_numericas):
    sns.boxplot(y=df[col], ax=eje, color="lightsteelblue")
    eje.set_title(f"{col}")
    eje.set_ylabel("")
plt.suptitle("Boxplots de las variables numéricas", fontsize=15)
mostrar_figura()
```




Figura 3: Boxplots de las variables numéricas.

```
cinco_numeros = resumen[["minimo", "q1", "mediana", "q3", "maximo",
                          "n_atipicos", "pct_atipicos"]].reset_index()
```

Tabla 18: Resumen de cinco números y valores atípicos de las variables numéricas.

variable	minimo	q1	mediana	q3	maximo	n_atipicos	pct_atipicos
edad	17.00	32.00	38.00	47.00	98.00	468	1.14
duracion_min	0.00	1.70	3.00	5.32	81.97	2,963	7.20
campana	1.00	1.00	2.00	3.00	56.00	2,406	5.84
dias_desde_contacto	0.00	3.00	6.00	7.00	27.00	82	5.41
contactos_previos	0.00	0.00	0.00	0.00	7.00	5,625	13.66
tasa_var_empleo	-3.40	-1.80	1.10	1.40	1.40	0	0.00
ipc	92.20	93.08	93.75	93.99	94.77	0	0.00
icc	-50.80	-42.70	-41.80	-36.40	-26.90	446	1.08
euribor3m	0.63	1.34	4.86	4.96	5.04	0	0.00
num_empleados	4,963.60	5,099.10	5,191.00	5,228.10	5,228.10	0	0.00

Análisis de los boxplots

- **edad:** la caja entre 32 y 47 años muestra una base concentrada en adultos en edad laboral. Los puntos por encima de 69.5 años (468 clientes) no son errores: corresponden a jubilados, un segmento pequeño pero relevante para un producto de ahorro de bajo riesgo.
- **duracion_min:** caja muy estrecha (1.70 a 5.32 min) y un bigote superior con una larga serie de atípicos hasta 82 minutos. La mayoría de las conversaciones es breve; las largas son excepcionales y, como se verá en el análisis multivariado, están muy asociadas a la aceptación.
- **campana:** la mediana está en 2 contactos y la caja llega solo hasta 3. Los atípicos, hasta 56 contactos, representan clientes a los que se insistió de forma desproporcionada, un costo operativo sin respaldo en la conversión.
- **dias_desde_contacto:** distribución compacta entre 3 y 7 días, lo que implica que el contacto previo suele haber ocurrido dentro de la última semana, con atípicos a partir de 14 días.
- **contactos_previos:** la caja colapsa en 0 y todos los valores positivos aparecen como atípicos. Esto ilustra una limitación del filtro por IQR cuando una variable tiene un valor extremadamente frecuente. Posiblemente el foco de las campañas era contactar clientes nuevos; dada la baja tasa de aceptación, esto también indica que se contactó sobre todo a clientes sin historial, lo que potencialmente contribuyó a no tener éxito en las campañas.

- **Indicadores macroeconómicos:** ninguno presenta atípicos. En `tasa_var_empleo`, `euribor3m` y `num_empleados` la mediana está pegada al borde superior de la caja: la mayoría de los contactos se hizo en un contexto de tasas y empleo altos, y una minoría relevante, en el contexto opuesto.

Tratamiento de los atípicos: no se eliminan. En `duracion_min`, `campana` y `edad` los valores extremos son plausibles y contienen información de negocio (llamadas exitosas, insistencia, jubilados). Eliminarlos borraría precisamente los casos que más interesa entender.

5.1.3. Histogramas de las variables numéricas

El histograma muestra la distribución de frecuencias. La forma de la distribución se describe visualmente y se apoya en la comparación entre la media y la mediana: cuando la media es mayor que la mediana, la distribución tiene una cola hacia valores altos (Figura 4).

```
fig, ejes = plt.subplots(2, 5, figsize=(20, 8))
for eje, col in zip(ejes.flatten(), variables_numericas):
    sns.histplot(x=df[col].dropna(), bins=30, ax=eje, color="steelblue")
    eje.set_title(f"{col}")
    eje.set_xlabel(col)
    eje.set_ylabel("Frecuencia")
plt.suptitle("Histogramas de las variables numéricas", fontsize=15)
mostrar_figura()
```




Figura 4: Histogramas de las variables numéricas.

```
forma = pd.DataFrame({
    "media": resumen["media"],
```

```
"mediana": resumen["mediana"],
"media_menos_mediana": resumen["media"] - resumen["mediana"],
"valores_distintos": [df[col].nunique() for col in variables_numericas],
}).reset_index()
```

Tabla 19: Comparación entre media y mediana, y número de valores distintos por variable.

variable	media	mediana	media_menos_mediana	valores_distintos
edad	40.02	38.00	2.02	78
duracion_min	4.31	3.00	1.31	1,544
campana	2.57	2.00	0.57	42
dias_desde_contacto	6.01	6.00	0.01	26
contactos_previos	0.17	0.00	0.17	8
tasa_var_empleo	0.08	1.10	-1.02	10
ipc	93.58	93.75	-0.17	26
icc	-40.50	-41.80	1.30	26
euribor3m	3.62	4.86	-1.24	316
num_empleados	5,167.03	5,191.00	-23.97	11

```
clases_edad = pd.cut(df["edad"], bins=range(10, 110, 10), right=False)
frecuencia_edad = (tabla_frecuencias(clases_edad).sort_index()
                    .reset_index(names="clase_edad"))
frecuencia_edad["clase_edad"] = frecuencia_edad["clase_edad"].astype(str)

frecuencia_campana = (tabla_frecuencias(df["campana"]).sort_index().head(10)
                      .reset_index(names="contactos"))
```

Tabla 20: Tabla de frecuencias de la edad por clases de 10 años.

clase_edad	frecuencia	porcentaje
[10, 20)	75	0.18
[20, 30)	5,592	13.58
[30, 40)	16,933	41.12
[40, 50)	10,523	25.56
[50, 60)	6,861	16.66
[60, 70)	724	1.76
[70, 80)	318	0.77

[80, 90)	140	0.34
[90, 100)	10	0.02

Tabla 21: Tabla de frecuencias del número de contactos en la campaña (primeros diez valores).

contactos	frecuencia	porcentaje
1	17,634	42.83
2	10,568	25.67
3	5,340	12.97
4	2,650	6.44
5	1,599	3.88
6	979	2.38
7	629	1.53
8	400	0.97
9	283	0.69
10	225	0.55

Análisis de los histogramas

- **edad:** distribución con cola hacia la derecha (media 40.02 > mediana 38). La tabla por clases (Tabla 20) muestra que el **41.12%** de los clientes tiene entre 30 y 39 años y el **80.26%**, entre 20 y 49. Los mayores de 60 años suman menos del 3%. La campaña se dirigió principalmente a adultos jóvenes y de mediana edad.
- **duracion_min:** fuerte asimetría hacia la derecha. La frecuencia cae de forma rápida después de los primeros minutos y aparece una cola larga (media 4.31 > mediana 3.00). La mayoría de las llamadas se resuelve rápido, probablemente con un rechazo temprano.
- **campana:** también muy asimétrica a la derecha. El **42.83%** de los clientes recibió un solo contacto, el 25.67% dos y el 12.97% tres (Tabla 21). A partir de ahí la frecuencia disminuye progresivamente, pero la cola se extiende hasta 56 contactos.
- **dias_desde_contacto:** los valores se concentran alrededor de 3 y de 6 días, con una segunda zona menor entre 10 y 15 días. La media y la mediana prácticamente coinciden (6.01 y 6).
- **contactos_previos:** casi toda la masa está en 0 y la frecuencia desciende de forma abrupta en 1 y 2 contactos.
- **Indicadores macroeconómicos:** no tienen una forma continua, sino **barras aisladas**, porque toman pocos valores distintos (10 en tasa_var_empleo, 11 en num_empleados y 26 en ipc e icc). Posiblemente se debe a que son indicadores trimestrales o mensuales que se repiten para todos los clientes contactados en un mismo periodo. En euribor3m (316 valores) se observan

dos zonas separadas: una por debajo de 2% y otra por encima de 4%, con muy pocos datos intermedios. Son los periodos de tasas bajas y altas señalados en el análisis de dispersión.

Implicancia: en la práctica, las variables macroeconómicas funcionan como indicadores del **periodo** en que se realizó el contacto, más que como mediciones continuas del cliente. Por ello, sus relaciones con la aceptación deben entenderse como diferencias entre contextos económicos, no entre personas.

5.1.4. Gráficos de barras y tablas de frecuencia de las variables categóricas

Para cada variable categórica se calcula la tabla de frecuencia absoluta y relativa, y se grafica con un gráfico de barras ordenado de mayor a menor frecuencia (salvo en las variables ordinales, que respetan su orden natural).

```
def grafico_barras_categoricas(datos, columnas, titulo, filas, cols):
    """Grafica un countplot por cada variable categórica."""
    fig, ejes = plt.subplots(filas, cols, figsize=(6 * cols, 4.8 * filas))
    ejes = ejes.flatten()
    for eje, col in zip(ejes, columnas):
        orden = (datos[col].cat.categories if datos[col].cat.ordered
                 else datos[col].value_counts().index)
        sns.countplot(x=datos[col], order=orden, ax=eje, color="steelblue")
        eje.set_title(f"{col}")
        eje.set_xlabel(col)
        eje.set_ylabel("Número de clientes")
        eje.tick_params(axis="x", rotation=45)
    for eje in ejes[len(columnas):]:
        eje.set_visible(False)
    plt.suptitle(titulo, fontsize=15)
    mostrar_figura()

def frecuencias_categoricas(datos, columnas):
    """Une en una sola tabla las frecuencias de varias variables categóricas."""
    tablas = [tabla_frecuencias(datos[col]).reset_index(names="categoria")
              .assign(variable=col) for col in columnas]
    return pd.concat(tablas)[["variable", "categoria", "frecuencia", "porcentaje"]]
```

```
grafico_barras_categoricas(df, variables_categoricas_perfil,
                           "Variables categóricas del perfil del cliente", filas=2, cols=
```




Figura 5: Gráficos de barras de las variables categóricas del perfil del cliente.

```
frecuencias_perfil = frecuencias_categoricas(df, variables_categoricas_perfil)
```

Tabla 22: Tablas de frecuencia de las variables categóricas del perfil del cliente.

variable	categoria	frecuencia	porcentaje
empleo	admin.	10,749	26.11
empleo	blue-collar	9,253	22.47
empleo	technician	6,739	16.37
empleo	services	3,967	9.63
empleo	management	2,924	7.10
empleo	retired	1,718	4.17
empleo	entrepreneur	1,456	3.54
empleo	self-employed	1,421	3.45
empleo	housemaid	1,060	2.57
empleo	unemployed	1,014	2.46
empleo	student	875	2.13
estado_civil	married	25,001	60.72
estado_civil	single	11,564	28.08
estado_civil	divorced	4,611	11.20
educacion	university.degree	12,164	29.54
educacion	high.school	9,512	23.10
educacion	basic.9y	6,045	14.68
educacion	professional.course	5,240	12.73

educacion	basic.4y	4,176	10.14
educacion	basic.6y	2,291	5.56
educacion	desconocido	1,730	4.20
educacion	illiterate	18	0.04
mora	no	32,577	79.12
mora	desconocido	8,596	20.88
mora	yes	3	0.01
vivienda	yes	22,561	54.79
vivienda	no	18,615	45.21
prestamo	no	34,928	84.83
prestamo	yes	6,248	15.17
grupo_etario	25-34	13,684	33.23
grupo_etario	35-44	13,495	32.77
grupo_etario	45-54	8,702	21.13
grupo_etario	55-64	3,566	8.66
grupo_etario	17-24	1,067	2.59
grupo_etario	65 o más	662	1.61

Observaciones de los gráficos de barras sobre el perfil de los clientes

- **empleo:** tres categorías concentran el **64.95%** de los contactos: admin. (26.11%), blue-collar (22.47%) y technician (16.37%). Estudiantes (2.13%), desempleados (2.46%) y jubilados (4.17%) son grupos minoritarios.
- **estado_civil:** predominan los casados (**60.72%**), seguidos de solteros (28.08%) y divorciados (11.20%).
- **educacion:** el nivel más frecuente es el universitario (**29.54%**), seguido de secundaria completa (23.10%). La categoría illiterate es atípica por su tamaño (18 clientes, 0.04%): cualquier porcentaje calculado sobre ella debe leerse con cautela.
- **mora:** la categoría yes tiene solo **3 clientes (0.01%)**, prácticamente inexistente. En la práctica, la variable distingue entre no (79.12%) y desconocido (20.88%).
- **vivienda:** el 54.79% tiene préstamo hipotecario, lo que muestra que más de la mitad de los clientes contactados ya tiene un compromiso financiero de largo plazo.
- **prestamo:** el 84.83% no tiene préstamo personal.
- **grupo_etario:** los grupos de 25-34 (33.23%) y 35-44 años (32.77%) concentran dos tercios de los contactos. Los extremos, 17-24 (2.59%) y 65 o más (1.61%), son poco frecuentes.

Implicancia: la campaña contactó mayoritariamente a adultos casados con empleo administrativo, técnico u obrero (Figura 5). Los grupos minoritarios (estudiantes, jubilados y clientes de 65 años o más) reciben pocos contactos. En el análisis multivariado se verifica si ese bajo contacto coincide o no con una baja aceptación.

```
grafico_barras_categoricas(df, variables_categoricas_campana,
                           "Variables categóricas de la campaña y del historial de contacto",
                           filas=2, cols=3)
```




Figura 6: Gráficos de barras de las variables categóricas de la campaña y del historial de contacto.

```
frecuencias_campana = frecuencias_categoricas(df, variables_categoricas_campana)
```

Tabla 23: Tablas de frecuencia de las variables categóricas de la campaña.

variable	categoria	frecuencia	porcentaje
tipo_contacto	cellular	26,135	63.47
tipo_contacto	telephone	15,041	36.53
mes	may	13,767	33.43
mes	jul	7,169	17.41
mes	aug	6,176	15.00
mes	jun	5,318	12.92
mes	nov	4,100	9.96
mes	apr	2,631	6.39
mes	oct	717	1.74

mes	sep	570	1.38
mes	mar	546	1.33
mes	dec	182	0.44
dia_semana	thu	8,618	20.93
dia_semana	mon	8,512	20.67
dia_semana	wed	8,134	19.75
dia_semana	tue	8,086	19.64
dia_semana	fri	7,826	19.01
resultado_previo	nonexistent	35,551	86.34
resultado_previo	failure	4,252	10.33
resultado_previo	success	1,373	3.33
contacto_previo	No	39,661	96.32
contacto_previo	Sí	1,515	3.68

Observaciones de los gráficos de barras sobre las campañas

- **tipo_contacto:** el 63.47 % de los contactos se hizo por celular y el 36.53 % por teléfono fijo.
- **mes:** la campaña está muy concentrada en el tiempo. **Mayo acumula el 33.43 %** de los contactos, y mayo, julio, agosto y junio suman el **78.76 %**. En cambio, marzo (1.33 %), septiembre (1.38 %), octubre (1.74 %) y diciembre (0.44 %) tienen muy poca actividad. No hay registros de enero ni febrero.
- **dia_semana:** distribución prácticamente uniforme entre lunes y viernes (19.01 % a 20.93 %). El día de la semana no refleja una estrategia diferenciada de la campaña.
- **resultado_previo:** el 86.34 % de los clientes no participó en campañas anteriores (nonexistent). Solo el 3.33 % tuvo un resultado previo exitoso.
- **contacto_previo:** el 96.32 % no había sido contactado antes, lo que confirma que la base es mayoritariamente nueva para el banco en términos de campañas.

Implicancia: la operación se concentró en pocos meses de alta actividad y en clientes sin historial (Figura 6). La categoría que identifica a un cliente con historial exitoso afecta solo a 1,373 personas; si ese grupo muestra una aceptación alta, representará una oportunidad pequeña en volumen pero muy eficiente.

5.2. Análisis multivariado

Para el análisis de relaciones entre variables numéricas se usan las nueve variables disponibles para todos los clientes. Se excluye `dias_desde_contacto`, porque solo existe para el 3.7 % de los clientes y compararla con las demás mezclaría subconjuntos distintos.

5.2.1. Covarianza

```
variables_relacion = ["edad", "duracion_min", "campana", "contactos_previos",
                      "tasa_var_empleo", "ipc", "icc", "euribor3m", "num_empleados"]

matriz_covarianza = df[variables_relacion].cov()
tabla_covarianza = matriz_covarianza.reset_index(names="variable")
```

Tabla 24: Matriz de covarianza de las variables numéricas (la diagonal contiene las varianzas)

variable	edad	duracion_min	campana	contactos_previos	tasa_var_empleo	ipc	icc	euribor3m
edad	108.59	-0.04	0.13	0.13	0.00	0.01	6.22	0.20
duracion_min	-0.04	18.68	-0.86	0.04	-0.19	0.01	-0.16	-0.25
campana	0.13	-0.86	7.67	-0.11	0.66	0.20	-0.18	0.65
contactos_previos	0.13	0.04	-0.11	0.24	-0.33	-0.06	-0.12	-0.39
tasa_var_empleo	0.00	-0.19	0.66	-0.33	2.47	0.70	1.43	2.65
ipc	0.01	0.01	0.20	-0.06	0.70	0.34	0.16	0.69
icc	6.22	-0.16	-0.18	-0.12	1.43	0.16	21.42	21.83
euribor3m	0.20	-0.25	0.65	-0.39	2.65	0.69	2.23	33.66
num_empleados	-13.26	-13.95	28.85	-17.93	102.94	21.83	33.66	

Análisis de la covarianza

- La diagonal contiene las varianzas: destaca la de num_empleados (5,220.26), muy superior al resto por la escala de la variable (miles de empleados), y la de edad (108.59).
- Signo de las relaciones** (Tabla 24):
 - Los indicadores macroeconómicos tienen **covarianzas positivas entre sí**: tasa_var_empleo con euribor3m (2.65), con num_empleados (102.94) y con ipc (0.70); euribor3m con num_empleados (118.44). Tienden a subir y bajar juntos.
 - contactos_previos tiene **covarianza negativa** con los indicadores macroeconómicos (-0.39 con euribor3m y -17.93 con num_empleados). Los clientes con más contactos previos se concentran en los periodos de tasas y empleo bajos.
 - duracion_min y campana covarían negativamente (-0.86): los clientes que recibieron más contactos tienden a tener llamadas más cortas.

Nota: la covarianza tiene una limitación: su magnitud depende de las unidades de cada variable. El valor 118.44 no implica una relación más fuerte que 2.65; solo refleja que num_empleados se mide

en miles. Por eso la intensidad de la relación se evalúa con la correlación de Pearson, que elimina el efecto de la escala.

5.2.2. Correlación de Pearson y mapa de calor

Usamos la correlación de Pearson, que lleva la covarianza al rango $[-1, 1]$ y permite comparar la intensidad de la relación lineal entre pares de variables con distintas unidades (Figura 7).

```
matriz_correlacion = df[variables_relacion].corr()

plt.figure(figsize=(10, 8))
sns.heatmap(matriz_correlacion, annot=True, fmt=".2f", cmap="coolwarm", vmin=-1, vmax=1,
            square=True, linewidths=0.5)
plt.title("Mapa de calor de la correlación de Pearson entre variables numéricas")
mostrar_figura()
```




Figura 7: Mapa de calor de la correlación de Pearson entre variables numéricas.

```
pares = []
for i, var1 in enumerate(variables_relacion):
    for var2 in variables_relacion[i + 1:]:
        pares.append({"variable_1": var1, "variable_2": var2,
```

```

        "r": matriz_correlacion.loc[var1, var2]})
pares = pd.DataFrame(pares)
pares["r_absoluto"] = pares["r"].abs()
pares = pares.sort_values("r_absoluto", ascending=False).reset_index(drop=True)

pares_top = pares.head(10)
pares_colineales = pares[pares["r_absoluto"] >= 0.8]
    
```

Tabla 25: Diez pares de variables con mayor correlación en valor absoluto.

variable_1	variable_2	r	r_absoluto
tasa_var_empleo	euribor3m	0.972	0.972
euribor3m	num_empleados	0.945	0.945
tasa_var_empleo	num_empleados	0.907	0.907
tasa_var_empleo	ipc	0.775	0.775
ipc	euribor3m	0.688	0.688
ipc	num_empleados	0.522	0.522
contactos_previos	num_empleados	-0.501	0.501
contactos_previos	euribor3m	-0.455	0.455
contactos_previos	tasa_var_empleo	-0.421	0.421
icc	euribor3m	0.278	0.278

Tabla 26: Pares con correlación absoluta mayor o igual a 0.8 (posible colinealidad).

	variable_1	variable_2	r	r_absoluto
0	tasa_var_empleo	euribor3m	0.972	0.972
1	euribor3m	num_empleados	0.945	0.945
2	tasa_var_empleo	num_empleados	0.907	0.907

Observaciones de la correlación

- **Colinealidad fuerte entre indicadores macroeconómicos.** Tres pares superan el umbral de 0.8 (Tabla 26):
 - tasa_var_empleo y euribor3m: $r = 0.97$ (positiva casi perfecta).
 - euribor3m y num_empleados: $r = 0.94$.
 - tasa_var_empleo y num_empleados: $r = 0.91$.

Estas tres variables se mueven prácticamente juntas: describen el mismo ciclo económico, de expansión antes de la crisis y de contracción después. Contienen información redundante y, en una etapa posterior, convendría no utilizarlas todas a la vez.

- **Relaciones moderadas:** ipc se asocia con tasa_var_empleo ($r = 0.78$) y con euribor3m ($r = 0.69$). contactos_previos tiene una correlación negativa moderada con num_empleados ($r = -0.50$), euribor3m (-0.46) y tasa_var_empleo (-0.42), coherente con lo observado en la covarianza.
- **Relaciones débiles o nulas:** icc apenas se relaciona con euribor3m ($r = 0.28$); la confianza del consumidor aporta información distinta a la del resto de indicadores. edad, duracion_min y campana tienen correlaciones cercanas a 0 con casi todas las demás variables.

5.2.3. Boxplots comparativos según la suscripción

Se compara la distribución de las variables numéricas entre los clientes que suscribieron y los que no, mediante boxplots lado a lado (Figura 8).

```
variables_comparar = ["edad", "duracion_min", "campana", "euribor3m", "icc", "num_emplead
orden_objetivo = ["No", "Sí"]

fig, ejes = plt.subplots(2, 3, figsize=(18, 10))
for eje, col in zip(ejes.flatten(), variables_comparar):
    sns.boxplot(x=df["suscribio"], y=df[col], hue=df["suscribio"], order=orden_objetivo,
                hue_order=orden_objetivo, palette="Set2", legend=False, ax=eje)
    eje.set_title(f"{col}")
    eje.set_xlabel("¿Suscribió?")
    eje.set_ylabel("")
plt.suptitle("Boxplots comparativos de variables numéricas según la suscripción", fontsize=14)
mostrar_figura()
```




Figura 8: Boxplots comparativos de variables numéricas según la suscripción.

```
filas = []
for col in variables_comparar:
    for grupo in orden_objetivo:
        serie = df.loc[df["suscribio"] == grupo, col]
        filas.append({"variable": col, "grupo": grupo, "media": serie.mean(),
                      "mediana": serie.median(), "q1": serie.quantile(0.25),
                      "q3": serie.quantile(0.75)})
medidas_por_grupo = pd.DataFrame(filas)
```

Tabla 27: Medidas de posición de las variables numéricas según la suscripción.

variable	grupo	media	mediana	q1	q3
edad	No	39.91	38.00	32.00	47.00
edad	Sí	40.91	37.00	31.00	50.00
duracion_min	No	3.68	2.73	1.58	4.65
duracion_min	Sí	9.22	7.48	4.22	12.36
campana	No	2.63	2.00	1.00	3.00
campana	Sí	2.05	2.00	1.00	2.00
euribor3m	No	3.81	4.86	1.41	4.96
euribor3m	Sí	2.12	1.27	0.85	4.41
icc	No	-40.59	-41.80	-42.70	-36.40

icc	Sí	-39.79	-40.40	-46.20	-36.10
num_empleados	No	5,176.17	5,195.80	5,099.10	5,228.10
num_empleados	Sí	5,095.12	5,099.10	5,017.50	5,191.00

Análisis de los boxplots comparativos

- **duracion_min:** es la diferencia más marcada. Quienes se suscribieron tienen una mediana de **7.48 minutos** frente a **2.73** de quienes no lo hicieron, y el primer cuartil de los que suscriben (4.22 min) casi coincide con el tercer cuartil de los que no (4.65 min). Las conversaciones que terminan en venta son mucho más largas. Esta relación **no puede usarse para priorizar clientes antes de llamar**, porque la duración solo se conoce después de la llamada, pero sí orienta la gestión: mantener la conversación es una condición para concretar la venta.
- **euribor3m:** los clientes que suscribieron fueron contactados con una Euribor mediana de **1.27 %**, frente a **4.86 %** en los que no suscribieron. La aceptación se concentra en el periodo de tasas bajas, lo que es coherente con el estudio original: tras la crisis, la preferencia por el ahorro seguro aumentó.
- **num_empleados:** tiene el mismo patrón. La mediana es 5,099 entre quienes suscriben y 5,196 entre quienes no; los periodos de menor empleo coinciden con una mayor aceptación.
- **campana:** la mediana es 2 contactos en ambos grupos, pero el tercer cuartil baja de 3 (no suscriben) a 2 (suscriben) y la media de 2.63 a 2.05. De ello deducimos que más insistencia no se traduce en más ventas.
- **edad:** medianas similares (37 y 38 años), pero la caja de quienes suscriben es más amplia, con un tercer cuartil de 50 años frente a 47; por ende, los clientes mayores tienen más presencia entre quienes aceptan.
- **icc:** diferencias pequeñas en la mediana (-40.4 frente a -41.8), aunque los que suscriben tienen un primer cuartil más bajo (-46.2); parte de las suscripciones ocurre en meses de confianza muy baja.

5.2.4. Mes de contacto y confianza del consumidor

Exploramos si la relación entre el mes de contacto y la aceptación coincide con cambios en el índice de confianza del consumidor. Para ello se combinan boxplots del índice por mes con la tasa de aceptación mensual (Figura 9 y Tabla 28).

```
plt.figure(figsize=(12, 5))
sns.boxplot(x=df["mes"], y=df["icc"], color="lightsteelblue")
plt.title("Índice de confianza del consumidor según el mes de contacto")
plt.xlabel("Mes de contacto")
```

```
plt.ylabel("Índice de confianza del consumidor (icc)")
mostrar_figura()
```




Figura 9: Índice de confianza del consumidor según el mes de contacto.

```
aceptacion_mes = tasa_aceptacion(df, "mes").drop("Total")
aceptacion_mes["icc_mediana"] = [df.loc[df["mes"] == m, "icc"].median()
                                for m in aceptacion_mes.index]
aceptacion_mes["pct_contactos"] = 100 * aceptacion_mes["contactos"] / len(df)
tabla_mes = aceptacion_mes.reset_index(names="mes")
tabla_mes["mes"] = tabla_mes["mes"].astype(str)
```

Tabla 28: Contactos, tasa de aceptación y mediana del índice de confianza del consumidor por mes.

mes	contactos	suscripciones	tasa_aceptacion_%	icc_mediana	pct_contactos
mar	546	276	50.55	-50.0	1.33
apr	2,631	539	20.49	-47.1	6.39
may	13,767	886	6.44	-36.4	33.43
jun	5,318	559	10.51	-41.8	12.92
jul	7,169	648	9.04	-42.7	17.41
aug	6,176	655	10.61	-36.1	15.00
sep	570	256	44.91	-37.5	1.38
oct	717	315	43.93	-26.9	1.74
nov	4,100	416	10.15	-42.0	9.96
dec	182	89	48.90	-33.0	0.44

Análisis del mes de contacto y la confianza del consumidor

- **Relación inversa entre volumen de contactos y aceptación.** Mayo concentra el 33.43 % de los contactos, pero tiene la **tasa más baja: 6.44 %**. En cambio, los meses con poca actividad tienen tasas muy altas: marzo (**50.55 %**), diciembre (**48.90 %**), septiembre (**44.91 %**) y octubre (**43.93 %**), todos con menos del 2 % de los contactos.
- **Confianza del consumidor por mes:** el boxplot muestra que cada mes tiene valores de *icc* muy concentrados, porque es un indicador mensual. Además, los meses de alta aceptación no comparten un mismo nivel de confianza: marzo (-50.0) y abril (-47.1) tienen la confianza **más baja**, mientras que octubre (-26.9) tiene la **más alta**. Por lo tanto, la confianza del consumidor por sí sola no explica la diferencia entre meses.
- **Nota:** la alta aceptación de los meses con pocos contactos puede reflejar que en esos periodos la campaña se dirigió a clientes más seleccionados, mientras que mayo parece corresponder a un contacto masivo. El dataset no permite confirmar esta explicación, por lo que queda como hipótesis.
- **Implicancia:** concentrar un tercio de las llamadas en un mes de baja conversión eleva el costo por depósito captado. Distribuir el esfuerzo y replicar la forma de trabajo de los meses de alta conversión es una línea de mejora a evaluar.

5.2.5. Histogramas por categoría

Se superponen los histogramas de cada grupo de la variable objetivo. Como el grupo que no suscribió es casi ocho veces más grande, cada histograma se normaliza por separado (densidad), de modo que se comparan las **formas** de las distribuciones y no sus tamaños (Figura 10).

```
variables_hist = ["edad", "duracion_min", "euribor3m"]

fig, ejes = plt.subplots(1, 3, figsize=(20, 5.5))
for eje, col in zip(ejes, variables_hist):
    sns.histplot(data=df, x=col, hue="suscribio", hue_order=orden_objetivo, bins=40,
                 stat="density", common_norm=False, element="step", ax=eje)
    eje.set_title(f"Distribución de {col} según la suscripción")
    eje.set_xlabel(col)
    eje.set_ylabel("Densidad")
plt.suptitle("Histogramas por grupo de suscripción", fontsize=15)
mostrar_figura()
```




Figura 10: Histogramas de edad, duración y Euribor según la suscripción.

```

filas = []
for col in variables_hist:
    for grupo in orden_objetivo:
        serie = df.loc[df["suscribio"] == grupo, col]
        filas.append({"variable": col, "grupo": grupo, "media": serie.mean(),
                      "mediana": serie.median(), "P10": serie.quantile(0.10),
                      "P90": serie.quantile(0.90)})
percentiles_por_grupo = pd.DataFrame(filas)

nivel_euribor = pd.Series(np.where(df["euribor3m"] < 3, "Euribor < 3%", "Euribor >= 3%"),
                           index=df.index, name="nivel_euribor")
aceptacion_euribor = (tasa_aceptacion(df.assign(nivel_euribor=nivel_euribor),
                                           "nivel_euribor")
                       .reset_index(names="nivel_euribor"))
    
```

Tabla 29: Media, mediana y percentiles 10 y 90 según la suscripción.

variable	grupo	media	mediana	P10	P90
edad	No	39.91	38.00	29.00	54.00
edad	Sí	40.91	37.00	26.00	60.00
duracion_min	No	3.68	2.73	0.92	7.45
duracion_min	Sí	9.22	7.48	2.82	17.84
euribor3m	No	3.81	4.86	1.27	4.96
euribor3m	Sí	2.12	1.27	0.71	4.96

Tabla 30: Tasa de aceptación según el nivel de la Euribor.

nivel_euribor	contactos	suscripciones	tasa_aceptacion_ %
Euribor < 3 %	13,494	3,300	24.46
Euribor >= 3 %	27,682	1,339	4.84
Total	41,176	4,639	11.27

Interpretación de los histogramas por grupo

- **edad:** las formas son parecidas en el centro (medianas de 37 y 38 años), pero la distribución de quienes suscriben es **más ancha en los extremos:** su percentil 10 es 26 años (frente a 29) y su percentil 90, 60 años (frente a 54). Deducimos que los clientes jóvenes y los mayores de 60 tienen más peso relativo entre quienes aceptan.
- **duracion_min:** la distribución de quienes no suscriben se concentra en los primeros minutos (percentil 90 = 7.45 min) y la de quienes suscriben está desplazada hacia la derecha: su percentil 10 es 2.82 min y su percentil 90, 17.84 min, lo que indica que casi no hay suscripciones en llamadas muy cortas.
- **euribor3m:** entre los no suscritos la masa se concentra en la zona de tasas altas (mediana de 4.86 %), mientras que entre los suscritos se concentra en la zona de tasas bajas (mediana de 1.27 %). La Tabla 30 lo confirma: con una **Euribor menor a 3 % la tasa de aceptación es 24.46 %** y con una Euribor de 3 % o más es solo **4.84 %**, cinco veces menor.

Implicancia: el contexto de tasas de interés bajas coincide con una propensión al ahorro mucho mayor. Para planificar campañas, el entorno económico es una variable tan importante como el perfil del cliente, recordando que esta tendencia proviene de un periodo histórico concreto (2008-2010).

5.2.6. Gráficos de barras agrupadas y tablas cruzadas

Las barras agrupadas muestran la frecuencia de cada categoría separada por la variable objetivo. Como el grupo “No” domina en todas las categorías, cada gráfico se acompaña de una tabla cruzada con la **tasa de aceptación** (frecuencia relativa por fila), que es la medida comparable entre categorías.

```
def barras_agrupadas(datos, columnas, titulo, filas, cols):
    fig, ejes = plt.subplots(filas, cols, figsize=(7 * cols, 5 * filas))
    ejes = ejes.flatten()
    for eje, col in zip(ejes, columnas):
        orden = (datos[col].cat.categories if datos[col].cat.ordered
                 else datos[col].value_counts().index)
        sns.countplot(data=datos, x=col, hue="suscribio", order=orden,
                      hue_order=orden_objetivo, palette="Set2", ax=eje)
```

```
eje.set_title(f"{col} según la suscripción")
eje.set_xlabel("")
eje.set_ylabel("Número de clientes")
eje.tick_params(axis="x", rotation=45)
for eje in ejes[len(columnas):]:
    eje.set_visible(False)
plt.suptitle(titulo, fontsize=15)
mostrar_figura()
```

```
def tasas_por_variable(datos, columnas):
    """Une en una sola tabla la tasa de aceptación de varias variables."""
    tablas = [tasa_aceptacion(datos, col).reset_index(names="categoria")
               .assign(variable=col) for col in columnas]
    return pd.concat(tablas)[["variable", "categoria", "contactos",
                              "suscripciones", "tasa_aceptacion_%"]]
```

```
columnas_campana = ["resultado_previo", "contacto_previo", "tipo_contacto", "tramo_duraci
barras_agrupadas(df, columnas_campana, "Variables de la campaña según la suscripción",
                  filas=2, cols=2)
```




Figura 11: Variables de la campaña según la suscripción.

```
tasas_campana = tasas_por_variable(df, columnas_campana)
```

Tabla 31: Tasa de aceptación por categoría de las variables de la campaña.

variable	categoría	contactos	suscripciones	tasa_aceptacion_%
resultado_previo	failure	4,252	605	14.23
resultado_previo	nonexistent	35,551	3,140	8.83
resultado_previo	success	1,373	894	65.11
resultado_previo	Total	41,176	4,639	11.27
contacto_previo	No	39,661	3,672	9.26
contacto_previo	Sí	1,515	967	63.83
contacto_previo	Total	41,176	4,639	11.27
tipo_contacto	cellular	26,135	3,852	14.74
tipo_contacto	telephone	15,041	787	5.23
tipo_contacto	Total	41,176	4,639	11.27
tramo_duracion	0-1 min	4,284	1	0.02
tramo_duracion	1-2 min	8,628	165	1.91
tramo_duracion	2-3 min	7,784	398	5.11

tramo_duracion	3-5 min	9,278	953	10.27
tramo_duracion	5-10 min	7,738	1,438	18.58
tramo_duracion	más de 10 min	3,464	1,684	48.61
tramo_duracion	Total	41,176	4,639	11.27

Análisis de las barras agrupadas de la campaña

- **resultado_previo:** los clientes con un éxito previo aceptan en un **65.11 %**, casi seis veces la tasa general. Incluso un fracaso previo (14.23 %) supera a los clientes sin campaña anterior (8.83 %), lo que indica que haber tenido contacto con el banco se asocia con una mayor apertura.
- **contacto_previo:** los clientes con historial de contacto aceptan en un **63.83 %**, frente a 9.26 % de los que nunca fueron contactados. En el gráfico de barras este grupo parece pequeño por su volumen (1,515 clientes), pero es el que más convierte.
- **tipo_contacto:** los contactos por celular convierten en un **14.74 %**, casi el triple que los de teléfono fijo (5.23 %).
- **tramo_duracion:** la tasa de aceptación crece de forma sostenida con la duración: **0.02 %** en llamadas de hasta 1 minuto, 1.91 % entre 1 y 2 minutos, 10.27 % entre 3 y 5 minutos, 18.58 % entre 5 y 10 minutos y **48.61 %** por encima de 10 minutos. Por debajo de los **3 minutos** la venta es muy improbable (5.11 % o menos); entre 3 y 5 minutos la tasa se acerca a la media general, y a partir de los **5 minutos** la supera con claridad. Esta variable es más útil para orientar a los agentes del call center que para seleccionar clientes antes de la llamada.

Implicancia: para priorizar clientes antes de contactarlos, la señal más útil disponible es el **historial de la relación** (resultado y existencia de contacto previo), seguida del tipo de teléfono (Figura 11).

```
columnas_perfil = ["grupo_etario", "empleo", "mora", "educacion"]
barras_agrupadas(df, columnas_perfil, "Variables del perfil del cliente según la suscripción",
                  filas=2, cols=2)
```




Figura 12: Variables del perfil del cliente según la suscripción.

```
tasas_perfil = tasas_por_variable(df, columnas_perfil)
```

Tabla 32: Tasa de aceptación por categoría de las variables del perfil del cliente.

variable	categoría	contactos	suscripciones	tasa_aceptacion_%
grupo_etario	17-24	1,067	256	23.99
grupo_etario	25-34	13,684	1,666	12.17
grupo_etario	35-44	13,495	1,168	8.66
grupo_etario	45-54	8,702	752	8.64
grupo_etario	55-64	3,566	484	13.57
grupo_etario	65 o más	662	313	47.28
grupo_etario	Total	41,176	4,639	11.27
empleo	admin.	10,749	1,388	12.91
empleo	blue-collar	9,253	638	6.90
empleo	entrepreneur	1,456	124	8.52
empleo	housemaid	1,060	106	10.00
empleo	management	2,924	328	11.22
empleo	retired	1,718	434	25.26

empleo	self-employed	1,421	149	10.49
empleo	services	3,967	323	8.14
empleo	student	875	275	31.43
empleo	technician	6,739	730	10.83
empleo	unemployed	1,014	144	14.20
empleo	Total	41,176	4,639	11.27
mora	desconocido	8,596	443	5.15
mora	no	32,577	4,196	12.88
mora	yes	3	0	0.00
mora	Total	41,176	4,639	11.27
educacion	illiterate	18	4	22.22
educacion	basic.4y	4,176	428	10.25
educacion	basic.6y	2,291	188	8.21
educacion	basic.9y	6,045	473	7.82
educacion	high.school	9,512	1,031	10.84
educacion	professional.course	5,240	595	11.35
educacion	university.degree	12,164	1,669	13.72
educacion	desconocido	1,730	251	14.51
educacion	Total	41,176	4,639	11.27

Análisis de las barras agrupadas del perfil de los clientes

- **grupo_etario:** la tasa de aceptación es alta en los extremos, **47.28%** en clientes de 65 años o más y **23.99%** en los de 17 a 24, y mínima en los grupos centrales de 35-44 y 45-54 años (8.66% y 8.64%). Precisamente los grupos centrales son los más contactados: las campañas concentran su esfuerzo en los segmentos que menos convierten.
- **empleo:** los **estudiantes (31.43%)** y los **jubilados (25.26%)** tienen las tasas más altas, seguidos por desempleados (14.20%) y administrativos (12.91%). Los obreros (blue-collar, 6.90%) y el personal de servicios (8.14%) tienen las más bajas. Este resultado es coherente con el patrón por edad de estudiantes y jubilados.
- **mora:** los clientes sin mora aceptan en un 12.88%, frente al 5.15% de aquellos cuyo dato es desconocido. La categoría yes (3 clientes, 0 suscripciones) es demasiado pequeña para interpretarse.
- **educacion:** entre las categorías con volumen notable, la aceptación aumenta con el nivel educativo, de 7.82% (basic.9y) a **13.72%** (university.degree). La categoría desconocido

(14.51%) también supera la tasa general, y illiterate (22.22%) no es concluyente porque tiene solo 18 clientes.

Nota: según estos patrones de conversión, reorientar parte del esfuerzo hacia jubilados, estudiantes y clientes con estudios superiores podría mejorar la conversión. Sin embargo, la asociación entre perfil y aceptación es descriptiva y no garantiza que contactar más a esos grupos mantenga las mismas tasas (Figura 12).

5.2.7. Diagramas de dispersión

Se analizan siete pares de variables numéricas, coloreando los puntos según la suscripción. Los cinco primeros pares corresponden a los indicadores macroeconómicos (Figura 13) y los dos últimos, a variables que describen las llamadas (Figura 14).

```
pares_macro = [("euribor3m", "num_empleados"), ("tasa_var_empleo", "euribor3m"),
               ("tasa_var_empleo", "num_empleados"), ("ipc", "euribor3m"),
               ("icc", "euribor3m")]

fig, ejes = plt.subplots(2, 3, figsize=(20, 11))
ejes = ejes.flatten()
for eje, (x, y) in zip(ejes, pares_macro):
    sns.scatterplot(data=df, x=x, y=y, hue="suscribio", hue_order=orden_objetivo,
                  palette="Set2", alpha=1, s=25, ax=eje)
    eje.set_title(f"{y} vs. {x}")
ejes[-1].set_visible(False)
plt.suptitle("Diagramas de dispersión de los indicadores macroeconómicos", fontsize=15)
mostrar_figura()
```




Figura 13: Diagramas de dispersión de los indicadores macroeconómicos.

```
filas = []
for x, y in pares_macro:
    filas.append({"par": f"{y} vs. {x}", "r": df[x].corr(df[y]),
                  "combinaciones_distintas": len(df[[x, y]].drop_duplicates())})
resumen_macro = pd.DataFrame(filas)
```

Tabla 33: Correlación de Pearson y número de combinaciones distintas por par de indicadores.

par	r	combinaciones_distintas
num_empleados vs. euribor3m	0.945	350
euribor3m vs. tasa_var_empleo	0.972	350
num_empleados vs. tasa_var_empleo	0.907	11
euribor3m vs. ipc	0.688	375
euribor3m vs. icc	0.278	375

Análisis de los diagramas de dispersión macroeconómicos

1. **num_empleados vs. euribor3m ($r = 0.945$):** tienen una relación lineal positiva muy fuerte. Los puntos forman **franjas horizontales** porque num_empleados es trimestral: dentro de cada trimestre el empleo es constante mientras la Euribor varía día a día. Además, los puntos de quienes suscriben se concentran en la parte inferior izquierda, con bajo empleo y tasas bajas.

2. **euribor3m vs. tasa_var_empleo ($r = 0.972$)**: es la relación más fuerte del dataset. Los puntos forman **columnas verticales**, una por cada valor trimestral de la tasa de variación del empleo. Cuando el empleo crece la Euribor es alta, y cuando el empleo cae la tasa es baja.
3. **num_empleados vs. tasa_var_empleo ($r = 0.907$)**: aquí solo existen **11 combinaciones distintas**, ya que ambas variables son trimestrales y cada punto representa un trimestre completo con cientos de clientes superpuestos. La relación es positiva, pero debe leerse con cuidado, ya que el cálculo se basa en muy pocas combinaciones repetidas miles de veces.
4. **euribor3m vs. ipc ($r = 0.688$)**: relación positiva moderada con agrupamientos verticales, uno por cada valor mensual del IPC. La asociación no es estrictamente lineal, ya que hay meses de IPC alto con tasas bajas.
5. **euribor3m vs. icc ($r = 0.278$)**: relación débil; con los mismos niveles de Euribor aparecen niveles muy distintos de confianza del consumidor, lo que confirma que el `icc` aporta información propia.

Conclusión:

- Los indicadores macroeconómicos se organizan en **grupos discretos** (periodos) y no en nubes continuas.
- La fuerte colinealidad entre `tasa_var_empleo`, `euribor3m` y `num_empleados` es real, pero proviene de pocos contextos económicos repetidos.
- El valor del coeficiente de Pearson por sí solo no describe la estructura de los datos; fue imprescindible graficar.

```
pares_operativos = [("edad", "duracion_min"), ("campana", "duracion_min")]

fig, ejes = plt.subplots(1, 2, figsize=(16, 6))
for eje, (x, y) in zip(ejes, pares_operativos):
    sns.scatterplot(data=df, x=x, y=y, hue="suscribio", hue_order=orden_objetivo,
                    palette="Set2", alpha=0.4, s=15, ax=eje)
    eje.set_title(f"{y} vs. {x}")
plt.suptitle("Diagramas de dispersión de variables operativas de la llamada", fontsize=15)
mostrar_figura()
```




Figura 14: Diagramas de dispersión de variables que describen las llamadas.

```
for x, y in pares_operativos:
    print(f"Correlación {y} vs {x}: r = {df[x].corr(df[y]):.3f}")
```

Correlación duracion_min vs edad: $r = -0.001$

Correlación duracion_min vs campana: $r = -0.072$

```
tramos_campana = pd.cut(df["campana"], bins=[0, 1, 2, 3, 5, 10, df["campana"].max()],
                        labels=["1", "2", "3", "4-5", "6-10", "más de 10"])

filas = []
for tramo in tramos_campana.cat.categories:
    sub = df[tramos_campana == tramo]
    filas.append({"contactos": tramo, "clientes": len(sub),
                  "duracion_media_min": sub["duracion_min"].mean(),
                  "tasa_aceptacion_%": 100 * (sub["suscribio"] == "Sí").mean()})
resumen_insistencia = pd.DataFrame(filas)
```

Tabla 34: Duración media de la llamada y tasa de aceptación según el número de contactos en la campaña.

contactos	clientes	duracion_media_min	tasa_aceptacion_%
1	17,634	4.28	13.04
2	10,568	4.66	11.46
3	5,340	4.50	10.75
4-5	4,249	4.04	8.68
6-10	2,516	3.61	6.32

más de 10	869	2.60	3.11
-----------	-----	------	------

Observaciones sobre los diagramas de dispersión de variables operativas (las que describen las llamadas)

6. **duracion_min vs. edad ($r = -0.001$):** la duración de la llamada es similar en todas las edades y los puntos de suscripción (duraciones altas) aparecen en todos los rangos de edad. Por el valor de la correlación, no hay relación lineal en este caso.
7. **duracion_min vs. campana ($r = -0.072$):** tienen una relación lineal débil y negativa, pero con un patrón interesante: a medida que aumenta el número de contactos, las duraciones largas desaparecen. La Tabla 34 lo cuantifica:
 - Con **1 contacto**, la duración media es de 4.28 minutos y la tasa de aceptación, **13.04 %**.
 - Entre 6 y 10 contactos, la duración baja a 3.61 minutos y la aceptación, a 6.32 %.
 - Con **más de 10 contactos**, la duración es de 2.60 minutos y la aceptación, solo **3.11 %**.

Implicancia: insistir sobre un mismo cliente se asocia con conversaciones más cortas y con una aceptación cuatro veces menor. Este resultado respalda la idea inicial de que existe una “insistencia excesiva” en las llamadas, y sugiere fijar un **límite de contactos por cliente**, ya que a partir del tercer contacto la tasa de aceptación (10.75 %) está por debajo de la media general y continúa cayendo.

Esto no es concluyente: como toda relación exploratoria, muestra una asociación y no una prueba de que el exceso de llamadas sea la causa del rechazo.

6. CONCLUSIONES

6.1. Hallazgos a nivel univariado

1. **Desbalance de la variable objetivo:** solo el 11.27% de los contactos terminó en suscripción (ratio 1 : 7.88). La campaña actual invierte la mayor parte de su esfuerzo en clientes que no convierten.
2. **Calidad de los datos:** no hay NaN explícitos, pero sí valores "unknown", sobre todo en mora (20.87%). El valor 999 de dias_previos indica "nunca contactado" (96.32% de los casos) y no una cantidad de días. Ambos se detectaron y trataron de forma justificada.
3. **Variables operativas muy asimétricas:** duracion_min y campana concentran sus valores en niveles bajos, con colas largas de atípicos que se conservaron por su valor de negocio.
4. **Campaña concentrada:** dos tercios de los contactos se dirigieron a clientes de 25 a 44 años, el 78.76% se realizó entre mayo y agosto, y el 96.32% fue a clientes sin historial previo.
5. **Indicadores macroeconómicos discretos:** toman pocos valores y describen mejor los periodos que las personas. La Euribor muestra dos periodos, de tasas altas (alrededor de 5%) y bajas (alrededor de 1%).

6.2. Hallazgos a nivel multivariado

1. **Historial del cliente:** un éxito en una campaña previa se asocia con una tasa de aceptación del **65.11%** y cualquier contacto previo, con un **63.83%**, frente a 9.26% sin historial.
2. **Contexto económico:** con una Euribor menor a 3% la aceptación es de **24.46%**; con 3% o más, de **4.84%**. Los periodos de tasas y empleo bajos coinciden con una mayor preferencia por el ahorro seguro.
3. **Perfil:** la aceptación es alta en los clientes más jóvenes, baja en las edades intermedias y vuelve a subir en los mayores: 47.28% en clientes de 65 años o más y 23.99% entre 17 y 24 años. Destacan estudiantes (31.43%) y jubilados (25.26%), y la aceptación aumenta con el nivel educativo.
4. **Canal e insistencia:** el celular convierte casi tres veces más que el teléfono fijo (14.74% frente a 5.23%). La aceptación cae de 13.04% con un contacto a 3.11% con más de diez.
5. **Estacionalidad:** mayo concentra un tercio de los contactos y tiene la tasa más baja (6.44%), mientras que marzo, septiembre, octubre y diciembre superan el 43%.
6. **Duración:** la aceptación sube de 0.02% en llamadas de hasta 1 minuto a 48.61% en llamadas de más de 10 minutos.

6.3. Colinealidad y posibles relaciones lineales

- Existe **colinealidad fuerte** entre tasa_var_empleo, euribor3m y num_empleados (r entre 0.91 y 0.97), y moderada con ipc (hasta 0.78). Estas variables contienen información redundante sobre el ciclo económico, por lo que bastaría seleccionar solo una de ellas como variable predictiva, por ejemplo euribor3m.
- icc tiene una relación débil con el resto ($r = 0.28$ con euribor3m) y aporta información complementaria.
- Las variables del cliente y de la llamada (edad, duracion_min, campana) no presentan relaciones lineales relevantes entre sí. El vínculo entre campana y duracion_min no es lineal y solo se aprecia al graficar.

6.4. Variables clave que aportaron valor al análisis

Tabla 35: Variables clave identificadas en el análisis exploratorio.

Variables	Nota
resultado_previo, contacto_previo, euribor3m (o un indicador macroeconómico equivalente)	Presentan las mayores diferencias en la tasa de aceptación y están disponibles antes de realizar la llamada.
edad / grupo_etario, empleo, tipo_contacto, mes, campana, mora, educacion	Tienen diferencias claras entre categorías y son útiles para segmentar la campaña.
dia_semana, estado_civil, vivienda, prestamo	Tienen una distribución uniforme o diferencias pequeñas en la aceptación, lo que las hace poco informativas para predecir la suscripción.
duracion	Está muy asociada a la aceptación, pero solo se conoce después de la llamada; usarla para predecir sería usar información que no existe al momento de decidir a quién llamar.

6.5. Consideraciones finales

- Todas las relaciones identificadas son **asociaciones descriptivas**: no asumimos que la correlación implique causalidad, y varias diferencias (por ejemplo, entre meses) pueden deberse a cómo se seleccionó a los clientes en cada periodo.

- Los datos provienen de un periodo específico (2008-2010) que corresponde a una crisis financiera europea, por lo que los patrones vinculados al contexto económico deben validarse antes de aplicarse a otros periodos.
- A partir de los hallazgos más importantes del EDA, sugerimos tres acciones: **priorizar a los clientes con historial de contacto, limitar la insistencia** a pocos contactos por cliente y **planificar las campañas considerando el contexto de tasas de interés**. La siguiente etapa de modelamiento deberá considerar el desbalance de clases y excluir la variable *duracion*.

Referencias

Moro, S, P Cortez y P Rita (2014). A data-driven approach to predict the success of bank telemarketing. *Decision Support Systems* **62**, 22-31.

Moro, S, P Rita y P Cortez (2014). *Bank Marketing*. UCI Machine Learning Repository. <https://archive.ics.uci.edu/dataset/222/bank+marketing>.